



固定 $Q = Q_0$ 的预算—N/D参考配置 (15个离散情景)

2,048 Token 8,192 Token 131,072 Token
 4,096 Token 32,768 Token B1 N/D支持上界

a



b



预算 (FLOPs, 对数轴; 线段仅连接三个给定档位)

固定 q_{huber} 基线、 $C_Q = 0$; 仅为B1实测网格和M0内的参考配置, 不是完整Q3联合最优。

最高预算点受B1支持网格上界约束; 线段不表示连续预算上的估计。