



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

新疆大学、山西大学

参赛队号

26107550075

队员姓名

1. 赵梦辰

2. 杨博尧

3. 张万杰

题 目: 【论文题目】

关键词: 【模型名1】 【模型名2】 【模型名3】 【模型名4】 【方法名】

目录

1	问题重述	5
1.1	问题背景	5
1.2	问题的提出	5
2	问题分析	7
2.1	总体技术路线	7
2.2	问题一分析	7
2.3	问题二分析	7
2.4	问题三分析	7
2.5	问题四分析	7
3	模型假设与符号说明	7
3.1	模型假设	7
3.2	符号说明	7
4	数据描述与预处理	9
4.1	数据来源与说明	9
4.2	数据探索与可视化	9
4.3	数据清洗与特征构建	9
5	问题一的模型建立与求解	10
5.1	问题一分析	10
5.2	模型建立	10
5.2.1	公共预处理与指标方向统一	10
5.2.2	质量评分模型	12
5.2.3	冲突度定义与消解规则	13
5.2.4	领域配比与损失的定量关系模型	14
5.3	模型求解	15
5.4	结果分析	17
5.4.1	质量评分结果	17
5.4.2	冲突分析与消解结果	19

5.4.3	配比—损失模型结果	20
5.5	模型验证与灵敏度分析	25
5.6	本章小结	28
6	问题二的模型建立与求解	30
6.1	问题二分析	30
6.2	模型建立	30
6.2.1	广义标度律的嵌套形式	30
6.2.2	边际效应与弹性的定义	31
6.3	模型求解	32
6.4	结果分析	33
6.4.1	经典分支的参数与拟合优度	33
6.4.2	边际效应与弹性	34
6.4.3	质量与规模的等损失兑换条件	36
6.4.4	大尺度外推情景	38
6.5	模型验证与灵敏度分析	39
6.5.1	分来源验证	39
6.5.2	损失量尺的可比性审计	39
6.5.3	配比与质量的可识别性	40
6.5.4	稳健性小结	41
6.6	本章小结	41
7	问题三的模型建立与求解	43
7.1	问题三分析	43
7.2	模型建立	43
7.2.1	优化模型与变量域	43
7.2.2	质量成本函数与临界上下文长度	44
7.2.3	结构性转移的定义与识别方法	44
7.3	模型求解	45
7.4	结果分析	45
7.4.1	上下文长度的可行取值	45
7.4.2	预算与上下文交叉下的参考配置	46
7.4.3	成本结构只由上下文长度决定	47
7.4.4	成本函数选择的影响	48

7.4.5 相邻情景的比较与条件性重分配	49
7.5 模型验证与灵敏度分析	50
7.6 本章小结	52
8 问题四的模型建立与求解	53
8.1 问题四分析	53
8.2 模型建立	53
8.3 模型求解	53
8.4 结果分析	53
8.5 模型验证与灵敏度分析	53
8.6 本章小结	53
9 模型稳健性与综合检验	54
9.1 参数灵敏度与随机性	54
9.2 消融实验	54
9.3 误差分解与失效案例	54
9.4 外推与分布偏移	54
10 模型的评价、改进与推广	55
10.1 模型的优点	55
10.2 模型的缺点	55
10.3 模型的改进方向	55
10.4 模型的推广	55
附录 A 问题一主要程序	56
附录 B 问题二主要程序	57
附录 C 问题三主要程序	58
附录 D 问题四主要程序	59
附录 E 人工智能使用披露	60
E.1 使用的 AI 工具	60
E.2 使用环节与贡献范围	60
E.3 对 AI 输出的核验与处理	60
E.4 由参赛队独立完成的工作	61

1 问题重述

1.1 问题背景

大语言模型的能力提升主要依赖三条途径：扩大参数规模、增加训练数据量、延长上下文长度。三者均需付出算力代价，且代价结构各异。参数量翻倍时，训练开销近似同倍增长；按经典估计，数据量应与参数量同比例增长，二者的乘积决定了基础训练开销的量级；上下文长度的代价增长更为迅速——从数千 token 扩展至数十万，注意力的计算量与 KV 缓存的显存占用同步上升，将迅速挤占本可分配给参数与数据的算力预算。然而，规模扩张并不必然带来能力提升。2026 年 2 月《Nature》刊载的一项研究提供了反例：参数量仅 80 亿的 OpenScholar-8B，在引文准确率与降低幻觉两项任务上超过了 GPT-4o。

该研究将差距归因于数据因素，即数据质量与领域配比，而非参数规模。这反映了当前大模型训练面临的现实约束：模型对高质量语料的需求持续增长，而满足要求的干净语料日益稀缺，数据污染日趋严重，即所谓“数据墙”问题。领域配比的作用尤为特殊：调整各领域数据的混合比例并不增加总算力开销，却改变算力在领域间的分配效果，进而影响最终的损失 [?]。

现有定量方法尚不足以回答“算力应投向何处”。广泛采用的标度律将交叉熵损失表示为参数量与数据量的幂函数之和，形式简洁、便于外推，但仅含参数量 N 与数据量 D 两个自变量，未显式纳入数据质量 Q 与领域配比 π [??]。换言之，上述两个被实践反复证明重要的因素，在该框架中只能以常数或噪声的形式出现。一旦将 Q 与 π 视为可调决策变量，经典形式即不再适用。另一方面，上下文长度通过长文本注意力开销压缩可用预算，该项亦未被经典标度律涵盖，其对最优配置的影响需单独解析，无法通过回归现有数据获得。因此，研究算力受限条件下的资源配置，须先将数据质量与领域配比纳入标度律，再在算力预算约束下，对参数量、数据量、领域配比与数据质量进行联合优化。

1.2 问题的提出

根据题目提供的三类附件数据，本文需完成以下四项工作。

问题一：数据质量评价、冲突消解与领域配比建模

题目所给质量信号数据覆盖 22 个评价维度，各维度方向不一致，教育价值越高越好而广告含量越低越好，建模前须将全部指标统一为“越高越好”。本文首先在抽样集 A1 上建立分位校准，把 22 个指标映射到同一无量纲尺度，并对中心型指标改用指数核处理；进而在该尺度上构造等权与稳定性加权 Huber 两个质量评分候选，并以稳定性加权 Huber 分为操作主分、以等权分为敏感性对照，同时以样本内平均两两绝对分差定义指标冲突度、以各来源域的第 95 百分位为高冲突阈值，并报告两候选之差作为消解结果；最后利用 512 条配方建立带单纯形约束的多输出收缩回归，刻画 17 域配比与 13 个损失目标之间的定量关系。模型在同尺度检验集 A6/A7 上取得 $R^2 = 0.619$ 、Spearman = 0.833，跨尺度检验集

A8–A11 的 R^2 转负而秩相关仍保持 0.73–0.83，据此将结论限定为同尺度内的配比筛选；外推表 A12–A15 用于估计表的一致性比对。

问题二：跨维度数据融合与广义标度律

本问要求将数据质量 Q 与领域配比 π 纳入标度律。附件 B 提供不同模型族、不同规模下的训练日志与损失记录，其中一部分为基于真实数据校准的半合成补充数据。本文以有效数据量折算的形式构造同时含参数量、数据量、数据质量与领域配比的广义标度律，以有界非线性最小二乘配合整轨迹整簇 bootstrap 完成参数估计与区间量化，据此计算各因素的无量纲弹性，并在半合成网格上给出质量提升与规模扩大可相互替代的等损失条件。

问题三：算力约束下的多维资源联合优化与结构性转移

本问在总算力预算受限的条件下完成资源分配。算力预算由三部分消耗：基础训练开销随参数量与数据量的乘积增长；数据质量由基线提升至目标水平需要额外算力，其规模取决于成本函数的形式；长文本注意力开销随上下文长度上升，且增速快于线性。上下文长度由题目外生给定，不作为寻优变量，但通过第三项开销影响前两项的可用预算，故仍须纳入模型。本文在冻结的经典标度律实测网格上建立约束优化模型，在低、中、高三档预算下求解最优的参数量、数据量与质量组合，解析给出使注意力开销与训练开销相当的临界上下文长度，并给出结构性转移的数学定义与识别方法。

问题四：技术演进分析与前沿能力预测

本问处理技术演进的定量分析。附件 C 提供开源模型的能力评测结果、算力与数据量元数据，以及损失与测评得分之间的桥接数据。本文以【方法】将模型能力增长分解为规模扩张与非规模技术进步两部分，分别量化二者的贡献占比，再以【方法】预测未来 12 个月与 24 个月的开源模型能力前沿，并给出不确定性区间。




图 2.1 本文总体技术路线图

2 问题分析

2.1 总体技术路线

2.2 问题一分析

2.3 问题二分析

2.4 问题三分析

2.5 问题四分析

3 模型假设与符号说明

3.1 模型假设

1. 【假设一：依据……，将……近似为……；该处理可能在……处产生……偏差，后文通过……（图/表编号）检查。】
2. 【假设二】
3. 【假设三】

3.2 符号说明

表 3.1 符号说明表

符号	含义	单位
i, j	索引（如节点、架次、样本）	—
N	规模参数（写明具体取值，如“取 $N=122$ ”）	—

(续表)

符号	含义	单位
x_{ij}	决策变量：……	—
θ	模型参数：……	【单位】
$\mathcal{L}$	目标函数：……	—

(提示：选题后删除本行，按需增删符号行)

4 数据描述与预处理

4.1 数据来源与说明

4.2 数据探索与可视化

4.3 数据清洗与特征构建

5 问题一的模型建立与求解

5.1 问题一分析

题目给出的数据分为两类。质量信号数据 A1–A3 覆盖 22 个评价维度，用于质量评价与冲突分析，其中 A1 是七个来源域的抽样集，A2 与 A3 分别为 arxiv 与 github 两个域的扩展集；配方实验数据 A4–A15 记录 17 个训练领域在不同混合比例下的交叉熵损失，A6–A11 为检验集，A12–A15 为外推表。两类数据采用不同的域分类体系，须借助 A16 的映射指南建立跨体系关联。本问需交付三项结果：方向统一后的质量评分 Q 、冲突的定义与消解规则，以及 17 域配比 π 与损失之间的定量关系模型。

建模的困难主要来自数据本身。22 个指标的方向与量纲均不一致，教育价值越高越好而广告含量越低越好，dsir 系列的中位数处于 -2100 量级而 rps 系列的比例型字段又在百分量级，直接加权没有意义。配比数据的结构同样特殊：17 个配比域中只有 13 个具备对应的验证损失，且训练集 512 条配方中有 511 条含零配比，逐分量的对数比变换会因零值而失效。配比表的行和只在三位小数的意义上等于 1，实测范围为 0.996–1.003，单纯形约束在数据中只是近似成立。三个数据集的规模差异亦不容忽视，A3 有 203752 条记录，为 A1 的 3.98 倍、A2 的 11.63 倍，若逐集重新拟合归一化参数，跨集比较将失去共同基准。

本问输出的 Q 与 π 是问题二的输入，问题二须在标度律中引入这两个量，因此本问必须给出 Q 的可比尺度与 π 的完整定义。

5.2 模型建立

5.2.1 公共预处理与指标方向统一

质量信号共 272505 条记录，分布为 A1 抽样集 51230 条、A2 扩展集 17523 条与 A3 扩展集 203752 条，预处理后的数据全貌见表 5.1。三集的行数在预处理前后完全一致，缺失率最高为 $18/51230 = 0.035\%$ 。异常标记按稳健标准化残差判定，阈值取 $|z| > 3.5$ ，其中

$$z_j(x) = \frac{x - m_j}{s_j}, \quad s_j = \begin{cases} 1.4826 \text{ MAD}_j, & \text{MAD}_j > 0 \\ \text{IQR}_j/1.349, & \text{MAD}_j = 0, \text{IQR}_j > 0 \\ \sigma_j, & \text{否则} \end{cases} \quad (5.1)$$

式中， m_j 为第 j 个指标的稳健中心， s_j 为其稳健尺度，优先取 1.4826 倍中位绝对偏差，当该量退化时依次回退到四分位距与标准差。该标记只用于标注而不作为删除依据，三集行数在预处理前后保持不变即是这条规则的直接结果。

方向统一在 A1 上一次性完成，A2/A3 只套用参数而不重新拟合。对第 j 个指标，记 $F_{j,A1}$ 为其在 A1 上拟合的分位函数，则

$$u_j(x) = \begin{cases} F_{j,A1}(g_j(x)), & \text{正向指标} \\ 1 - F_{j,A1}(g_j(x)), & \text{负向指标} \\ \exp\left(-\frac{|g_j(x) - m_j|}{s_j}\right), & \text{中心型指标} \end{cases} \quad (5.2)$$

式中， g_j 为指标的原始变换（词数、句数两个字段先取 $\log(1+x)$ ）， $u_j \in [0, 1]$ 为方向统一后的无量纲得分，对任何指标，取值越接近 1 表示该维度上的质量越好。三类方向中，中心型指标的含义略有不同：偏离中位过远（无论偏高还是偏低）都会被扣分，故采用指数核而非单调映射。分位函数在 2001 个分位点上取值，两端按 $[0.005, 0.995]$ 截尾，截尾避免极值把尺度拉长，代价是极端样本被压缩到端点。列表型字段先压缩为标量再参与上述流程，规则见表 5.2。

表 5.1 A1–A3 的样本规模、缺失与异常标记

数据集	原始行	处理后行	缺失值	非法值	单位疑似	异常标记
A1	51230	51230	18	0	4	63708
A2	17523	17523	0	0	0	75785
A3	203752	203752	1	0	16	385678

表 5.2 列表型指标到标量的压缩规则

字段	列表长度	压缩方式	理由
fineweb_edu	1	取唯一元素	本身即单值
ad_en、fluency_en	2	softmax 后取第 2 类	第 2 类为正向事件
modernbert_*	6	期望等级 $\div 5$	有序等级，取期望保序
qurater	4	算术平均	四个子维度等权

22 个指标中有 7 个 `rps_*frac*` 字段的上游精确生成公式尚未追溯。这批字段在 A1 与 A3 中分别有 4 行与 16 行的取值大于 1，其中 `top_2gram` 与 `top_3gram` 两类还各有 2 行超过 100。本文对该 7 个字段在 A1 全部 51230 条记录上做了独立复算：以公开 RedPajama 实现对原文重新计算后，取值尺度与存储值一致，故按百分数尺度存储的判断有直接证据；超过 100 的两行来自重叠 n -gram 的重复计数，是该公式的数学性质而非错误。因此本文不对这批字段做替换、截断或整体除以 100——在 A1 上拟合的经验分位函数与稳健标准

化对全体记录施加同一常数倍变换，该常数在分位映射中自然抵消。仍存留的限制在于上游生成版本与行级列表聚合规则未能追溯，其中一个字段的实测语义与其名称不符。本文将作为语义不确定性的上界场景在 5.5 中探测，而不据此认定数据损坏。22 个指标经方向统一后的分布见图 5.1。




图 5.1 22 个质量指标经方向统一后的分布（红色标签为 7 个上游生成公式未追溯的字段）

5.2.2 质量评分模型

质量评分给出两个候选，二者的差别只在样本内的聚合方式。等权候选选取 22 个 u_j 的算术平均，

$$Q_{\text{eq}}(x) = \frac{1}{J} \sum_{j=1}^J u_j(x), \quad J = 22 \quad (5.3)$$

稳定性加权候选则以 Huber 位置估计替代算术平均，其权重由指标完整度与排序稳定性两部分相乘得到：

$$w_j = \frac{r_j}{\sum_k r_k}, \quad r_j = (c_j \cdot S_j)^\alpha \quad (5.4)$$

式中， c_j 为该指标在 A1 上的完整度（非缺失记录占比）， S_j 为域排序稳定性——将 A1

七个来源域各自的中位数排序重复抽样 1000 次，取该指标秩相关的中位数； α 为权重指数，主口径取 $\alpha = 1$ 。代入后 18 个指标的权重为 0.045492，其余 4 个因完整度或稳定性略低而略小：`modernbert_reasoning` 与 `modernbert_professionalism` 的完整度分别为 0.9997 与 0.9999，权重降至 0.045486 与 0.045490；`qurater` 与 `rps_lines_numerical_chars_fraction` 的排序稳定性为 0.9821，权重取最小值 0.0450840。权重指数取 $\alpha = 0.5$ 与取 $\alpha = 1$ 在本数据上给出完全相同的样本分，最大绝对差为 0、秩相关为 1，原因在于各指标的 r_j 本身接近，幂次不足以进一步区分，故不需在 α 上继续搜索。

Huber 位置的阈值取 $\delta = 1.345 s_0$ ，其中 $s_0 = 1.4826 \text{ MAD} = 0.29484$ ，得 $\delta = 0.39655$ 。系数 1.345 是标准正态下 95% 效率对应的常数，其含义是残差在 δ 以内按平方损失处理，超出后转为线性，从而把单个指标极端取值的影响限制在有界范围。样本分向域级聚合按域内 Huber 位置计算，并给出 $B_Q = 2000$ 次记录级 bootstrap 的百分位 95% 区间。权重校准的过程见图 5.2，完整的评分流程见图 5.3。

两个候选须指定其一作为对外接口，否则问题二与问题三将失去单一的质量输入。本文的指定依据是可用的判据无法区分二者：全部敏感性场景下两者的样本分高度一致，小样本人工核查的候选比较亦给出相同的秩相关（见 5.5）。在此前提下，本文取稳定性加权 Huber 分 Q_{huber} 作为操作主分（版本记 `Q1-q_huber-v1`），等权分 Q_{eq} 保留为敏感性对照。该指定的性质是接口一致性选择，而非统计或人工评审判定的优胜；后文凡称 Q 而未加下标者，均指 Q_{huber} 。

5.2.3 冲突度定义与消解规则

当不同质量指标对同一文本给出不一致评价时，需要定义冲突、分析成因并给出消解规则。本文把冲突定义为指标之间的分歧幅度，用行内平均两两绝对分差度量：

$$D(x) = \frac{2}{J(J-1)} \sum_{1 \leq j < k \leq J} |u_j(x) - u_k(x)|, \quad \binom{22}{2} = 231 \quad (5.5)$$

式中， $u_j(x)$ 为样本 x 在第 j 个维度上方向统一后的得分。 D 只衡量指标之间是否互相矛盾，不判定哪一项指标有误——在缺少外部真值的条件下，无从判断 `dsir_math` 与 `rps_doc_unigram_entropy` 二者孰是孰非。高冲突阈值取 A1 各来源域内 D 的第 95 百分位（NumPy method=linear 插值），A2/A3 一律套用同名域的 A1 阈值以保证跨集可比；消解规则采用稳定性加权 Huber 位置，并报告两候选之差 $\Delta Q = Q_{\text{huber}} - Q_{\text{eq}}$ 。

上述阈值属于描述性的上尾截断而非假设检验：以 q_{95} 作阈值意味着高冲突样本恒占 5%，这是定义使然，不能读作“5% 的样本确实存在冲突”。冲突度与阈值的联合作用在于给出排序，而非作出绝对判定。冲突诊断与消解的完整流程见图 5.4。




图 5.2 指标权重的两个构成分量：完整度与排序稳定性

5.2.4 领域配比与损失的定量关系模型

配比建模只使用 A4/A5 的 512 条训练配方，其配比矩阵 $P \in \mathbb{R}^{512 \times 17}$ 的每一行满足单纯形约束，待预测的损失矩阵 $Y \in \mathbb{R}^{512 \times 13}$ 含 13 个目标。配比域比损失目标多 4 个，这 4 个域的损失无从观测，只能在回归中作为不可观测分量处理，这是模型的结构性限制。配比先做闭合归一化 $p_{rj} = x_{rj} / \sum_k x_{rk}$ ，同时保留原始版本用于对照；闭合的必要性在于行和并非精确为 1，实测范围为 0.996–1.003。闭合同时改变了零单元的语义，原始零配比在闭合后仍是零，但非零分量会被等比放大，故 512 条配方的最近邻 L_1 距离由 0 变为 0.0220。

主模型为带单纯形约束的多输出收缩回归。记参考域为 j_0 ，模型写成

$$\hat{y}_{ri} = a_i + \sum_{j \neq j_0} \beta_{ij} p_{rj}, \quad \text{s.t.} \sum_{j=1}^{17} \beta_{ij} = 0, \quad i = 1, \dots, 13 \quad (5.6)$$

式中， a_i 为第 i 个损失目标的截距， β_{ij} 为第 j 个域的配比系数，约束 $\sum_j \beta_{ij} = 0$ 消去“全部域同比例增加”这一不可辨识方向——配比之和恒为 1，系数只有满足该约束才唯一。参考域取 `uspto_backgrounds`，其系数固定为 0，收缩强度由岭参数 λ 控制，主口径取 $\lambda = 10^{-4}$ ，由 A4/A5 内部的分组交叉验证网格选出。

质量评分 Q 是否进入配比模型由参赛队伍自行论证。本文不引入 Q ，理由是识别性：若把 Q 作为与配比并列的回归项，模型形如 $p^\top b + \theta Q$ ，而 Q 的域级取值本身就是各域配





图 5.3 质量评分的建模流程

比的函数，两者在 $p^T(b + \theta\tilde{Q})$ 的意义下不可分别识别，在缺少外部真值的前提下强行加入只会使系数失去解释。因此本文改用配比单独建模，把 Q 留给问题二的标度律处理。

除主模型外，另设四个对照与敏感性变体，即训练均值空模型（下界）、参考分量 OLS（截距加 16 个分量、参考系数固定为 0）、Huber 岭回归（ $\rho_{1.345}$ ，用于检验异常损失的影响）与零友好的二次面（17 个一次项与 136 个两两乘积项，共 153 项）。二次面仅作敏感性对照，153 个系数由 512 条配方估计，过拟合风险明显，故不参与模型族选择。选模过程完全在 A4/A5 的分组交叉验证内完成，A6–A11 只用于评估冻结后的模型，A12–A15 只用于与估计表比对一致性，不参与任何调参。配比与各损失目标之间的相关系数见图 5.5。



标记只用于敏感性分组；原文不进入统计，不据此认定恶意，也不证明评分器免疫污染。
主分支只读冻结 norm_*；污染支路仅重估 A1 校准；A2 / A3 复核限于冻结评分表。

图 5.4 冲突诊断与消解的建模流程




图 5.5 配比与损失目标之间的相关系数结构（红色标签为 4 个无对应验证损失的配比域）

5.3 模型求解

求解流程分四步，依次是归一化校准、权重构造、配比回归与不确定性估计。权重中的域排序稳定性通过重复抽样估计，Huber 位置用迭代重加权最小二乘求解，配比回归的岭参数在网格上按分组交叉验证误差选取，替代效应则用配对 bootstrap 给出区间，配比回归部分的伪代码见表 5.3。

表 5.3 带单纯形约束的多输出回归求解步骤

步骤	操作
1	读入配比矩阵 P 与损失矩阵 Y ，按行闭合 $p_{rj} \leftarrow x_{rj} / \sum_k x_{rk}$
2	按来源分组 (index) 划分 K 折，保证同组不跨折
3	for 每个候选 λ do 在 K 折上计算标准化 MSE
4	选 $\hat{\lambda} = \arg \min_{\lambda} CV(\lambda)$ ，重拟合得 $\hat{B}, \hat{a}$
5	if 用 Huber 变体 then IRLS 迭代至权重收敛 (最大 13 轮)
6	用 $\hat{B}, \hat{a}$ 预测 A6–A11，按目标汇总 MAE/RMSE/ R^2 /Spearman
7	对每个域对做 500 次配对 bootstrap，得 10 个百分点替代效应的 95% 区间

求解的可靠性可由三项收敛证据支持：Huber 变体在 13 个损失目标上全部收敛，最大迭代 13 轮；各目标被降权的训练配方数最多为 24 条 (arxiv 与 github)，权重低于 0.5 的仅 1 条；参考分量 OLS 的设计矩阵条件数在五折内为 [198.7, 209.4, 235.0, 204.9, 206.6]，远低于 10^7 的病态告警阈值。

5.4 结果分析

5.4.1 质量评分结果

A1 七域的域级质量评分见表 5.4，两候选的宏平均分别为 0.49622 (等权，95% 区间 [0.49491, 0.49763]) 与 0.49848 (Huber, [0.49657, 0.50043])。两候选给出的排名基本一致，分歧集中在 book 与 github 两个域：等权分把 book 排在 github 之前 (0.43160 对 0.40450)，Huber 分则把两者拉近 (0.42875 对 0.38948)，差异的来源可从 5.5 的冲突分析中找到——book 正是指标分歧最大的域。各域评分及其区间见图 5.6。两候选的取舍依据来自小样本人工核查与全部敏感性场景，其证据与边界在 5.5 中一并报告。

同域迁移检验的结果见表 5.5。A2 与 A3 分别是 A1 中 arxiv 与 github 两个域的扩展集，由于归一化参数只在 A1 上拟合，同域扩展集相对抽样集的评分偏移即反映标量层面的可比性。四个差值的 95% 区间全部跨零，点估计均在千分位以下，说明在 A1 上拟合的参数

表 5.4 各来源域的域级质量评分（等权与加权两候选）

数据集	来源域	记录数	Q_{eq}	Q_{huber}
A1	arxiv	1419	0.53210	0.56133
A1	book	171	0.43160	0.42875
A1	c4	10000	0.57053	0.57673
A1	commoncrawl	9640	0.53401	0.53597
A1	github	10000	0.40450	0.38948
A1	stackexchange	10000	0.51734	0.51837
A1	wikipedia	10000	0.48349	0.47871
A2	arxiv	17523	0.53096	0.55997
A3	github	203752	0.40394	0.38887




图 5.6 各来源域的域级质量评分及估计区间

直接套用到两个扩展集时，域级评分没有可检出的偏移。差值及其区间另见图 5.7。这一比较限定在标量层面，A2/A3 的特征文件不含原文内容，原文层面的效度验证需借助 A18 的原始文本样例另行完成。

表 5.5 同域扩展集相对抽样集的评分偏移（bootstrap 区间）

对比	候选	差值	95% 区间
A2 arxiv – A1 arxiv	Q_{eq}	-0.00114	[-0.00288, 0.00070]
A2 arxiv – A1 arxiv	Q_{huber}	-0.00136	[-0.00399, 0.00128]
A3 github – A1 github	Q_{eq}	-0.00056	[-0.00185, 0.00086]
A3 github – A1 github	Q_{huber}	-0.00061	[-0.00211, 0.00085]




图 5.7 同域扩展集与 A1 的域分差值

5.4.2 冲突分析与消解结果

各域的中位冲突度与 q_{95} 阈值见表 5.6。arxiv 的中位冲突度最高(0.4382), stackexchange 最低 (0.2712)，两者相差 0.167；扩展集的冲突度与同域 A1 高度接近，A2 为 0.4393、A3 为 0.3236。表中 A1 各域的高冲突率恒为 0.0500，这是 q_{95} 阈值的定义使然；A2 的 0.0447 与 A3 的 0.0514 则说明扩展集在套用 A1 阈值后，落入高冲突区的比例与原集基本一致。各域的冲突度分布与阈值见图 5.8。

指标对层面的分歧结构更为具体。A1 七域宏平均下冲突最激烈的三对依次是 dsir_math 与 rps_doc_unigram_entropy (0.5993)、dsir_wiki 与同一元熵指标 (0.5963)、dsir_books 与同一元熵指标 (0.5953)，三对均含 rps_doc_unigram_entropy，其成因可以解释：dsir 系列衡量文本与某一参考语料的相似度，而一元熵衡量文本自身词汇分布的分

表 5.6 各来源域的冲突度水平与高冲突判定阈值

数据集	来源域	中位冲突度	q_{95} 阈值	高冲突率
A1	arxiv	0.4382	0.4660	0.0500
A1	book	0.4098	0.4476	0.0526
A1	c4	0.3241	0.4188	0.0500
A1	commoncrawl	0.2883	0.3834	0.0500
A1	github	0.3232	0.4294	0.0500
A1	stackexchange	0.2712	0.3598	0.0500
A1	wikipedia	0.3069	0.4079	0.0500
A2	arxiv	0.4393	0.4660	0.0447
A3	github	0.3236	0.4294	0.0514

散度，后者高的文本未必与任何参考语料接近，两者的评价对象并不相同。231 个指标对的分歧结构见图 5.9。

消解后的评分为 Q_{huber} 。在高冲突组内，两候选的差值方向并不统一，**github** (-0.0497)、**wikipedia** (-0.0330) 与 **c4** (-0.0056) 为负，而 **arxiv** ($+0.0438$)、**book** ($+0.0393$) 与 **commoncrawl** ($+0.0127$) 为正。**book** 域的分歧幅度尤为突出，其高冲突组的 $|\Delta Q|$ 中位数为 0.0393，是其余组 0.01973 的两倍，与表 5.6 中 **book** 唯一非 0.05 的高冲突率互为印证。扩展集上的外部复核结果见图 5.10。

冲突度与评分分歧幅度的关系见图 5.11。

5.4.3 配比—损失模型结果

模型选择的结果见表 5.7。三个主要候选的差别不大但有稳定顺序，单纯形岭回归的分组交叉验证标准化 MSE 为 0.39860，略优于参考分量 OLS 的 0.40032，两者都远优于训练均值空模型的 1.00448。模型族的交叉验证对比见图 5.13。主模型相对基线的逐目标改善见图 5.12。

主模型在 A4/A5 上的嵌套交叉验证给出宏平均 $R^2 = 0.59923$ 、Spearman $\rho = 0.82077$ 、MAE = 0.41972、RMSE = 0.49780，五折的外层选模全部选中同一个模型族，选模流程本身稳定。冻结检验集与估计表上的表现见表 5.8。

同尺度的 A6/A7 上模型表现可用， R^2 为 $+0.619$ ；跨到 60M 与 1B 后 R^2 急剧转负，但同期 Spearman 仍保持在 0.73–0.83。二者的差异指向不同的失效机制： R^2 的负值来自尺度




图 5.8 各来源域的域内冲突度分布（虚线为该域的 q_{95} 高冲突阈值，灰竖线为域内中位数）

表 5.7 三种配比模型族的分组交叉验证误差

模型	标准化 MSE↓	正则强度 λ	角色
单纯形岭回归（主模型）	0.39860	10^{-4}	选中
参考分量 OLS	0.40032	—	对照
Huber 岭回归	0.40165	3.16×10^{-5}	稳健性敏感性
二次面（153 项）	0.34238	0.2848	非线性敏感性
训练均值空模型	1.00448	—	下界




图 5.9 质量指标两两冲突强度的分布（琥珀色为 dsir 系列与一元熵的组合）




图 5.10 冲突指标在扩展集上的复核结果。两者是量纲不同的量，故分列两栏：(a) 域内中位冲突度之差；(b) 高冲突率之差。区间跨零即无可检出差异

失配——随训练尺度增大，各域验证损失的整体水平下降，而主模型的系数在 1M 尺度上估计、不含任何尺度项，无法跟随均值漂移；Spearman 则说明模型的排序能力仍然保留。据此，该模型的适用范围限定为同一训练尺度内的配比筛选，不能作为跨尺度的定量外推工具。同尺度留出集上的观测值与预测值对照见图 5.14，跨尺度 RMSE 见图 5.15。




图 5.11 冲突度与评分分歧幅度的关系




图 5.12 主模型相对训练均值基线的拟合误差改善




图 5.13 三种配比模型族的分组交叉验证误差

表 5.8 各检验尺度上的预测误差与秩相关（13 个目标宏平均）

数据	尺度关系	MAE↓	RMSE↓	R^2 ↑	Spearman↑
A6/A7 (1M)	同尺度	0.3876	0.4539	+0.6189	0.8327
A8/A9 (60M)	跨尺度	1.5125	1.5590	-7.9336	0.8314
A10/A11 (1B)	跨尺度	3.1830	3.1970	-810.12	0.7268
A12/A13 (10B)	外推估计表	3.5730	3.6016	-236.86	0.4896
A14/A15 (70B)	外推估计表	3.9556	3.9848	-385.31	0.4132




图 5.14 同尺度留出集上预测损失与观测损失的一致性




图 5.15 检验尺度对预测误差与秩相关的影响：误差随尺度恶化而秩相关保持

替代效应的方向结构见表 5.9。136 个域对中有 106 对在训练集上有足够份额支持 10 个百分点的替代，其 1378 个目标与域对组合的区间中，214 个全为正、535 个全为负、629 个跨零。区间跨零占近一半，说明多数替代方向在本数据上尚无定论。这些区间条件于已选模型族、已选 λ 与观测训练分布，逐点计算且未做多重比较校正，系数只反映关联而非因果效应，故区间本身不作为显著性结论。替代关联系数见图 5.16。

表 5.9 配比替代效应区间估计的方向构成

类别	数量	占比
受支持的域对	106	77.9% (占 136 对)
区间全为正	214	15.5%
区间全为负	535	38.8%
区间跨零	629	45.7%
不受支持的域对	30	22.1% (占 136 对)

各组合的方向确定性见图 5.17。

各检验集上误差最大的目标一并列出：A6/A7 上为 `the_pile_dm_mathematics_val_loss` (RMSE 1.1634)，A8/A9 与 A10/A11 上均为 `github` (2.6333 与 4.4280)，A12/A13 与 A14/A15 上均为 `ubuntu_irc` (4.4513 与 4.9323)。最大的预测五分位偏差出现在 `dm_mathematics` 的第 5 组，预测减观测为 -0.5174 ，即高损失区存在系统性低估。




图 5.16 配比替代效应的关联系数结构（系数满足 $\sum_j \beta_{ij} = 0$ ，参考域固定为 0）

5.5 模型验证与灵敏度分析

本节的验证围绕一个目标：考察前述结论对预处理参数、权重构造与数据中异常记录的稳定性，主要场景见表 5.10。

表 5.10 评分对字段与权重设定的敏感性

敏感性场景	样本分 P95 绝对差 ↓	排序 Spearman ↑	判读
剔除上游公式未追溯字段	0.113048	0.872404	影响最大，排序仍稳
Huber 阈值 $\delta \times 0.5$	—	0.980320	影响有限
权重指数 $\alpha = 0.5$	0	1.000000	完全等价
剔除带单位标记的 A1 行	10^{-6}	1.000000	可忽略

影响最剧烈的是剔除 7 个上游公式未追溯字段，A1 样本分的 P95 绝对差达 0.113048、最大差 0.255681，A2 上的秩相关降到 0.729556。这一场景的作用是给出语义不确定性的上界探测：把 7 个字段整体移出后评分变化的上限即在上述量级，它衡量的是评分对这批语




图 5.17 配比替代效应的方向确定性（1768 个目标与域对组合中 895 个方向稳定）

义未定字段的依赖程度，而不是数据存在错误的证据——独立复算已表明其取值尺度为百分数存储，超过 100 的少数记录源自重叠 *n*-gram 的重复计数。基于这一量级，本文不把 *Q* 称为 22 路信号的完整综合，而称其为受限候选分，并在正文中逐列明仍然存疑的字段。相比之下，Huber 阈值折半只带来 0.007374 的宏平均位移（秩相关 0.980），权重指数 α 的选择则完全不影响结果。

参数与字段层面的稳健性之外，评分还须经过一次独立于建模过程的外部核验。受人工评审工作量限制，本研究未实施 793 条样本的双人全量评分，而采用 30 条小样本双评者核查，其中 24 条代表性样本用于候选比较，6 条诊断性样本用于案例检查。两位评审的总体质量评分具有一定一致性，二次加权 Cohen $\kappa = 0.765$ ，评审间 Spearman 相关为 0.806。但两份回收表顺序相同，评审材料采用中文机译辅助版本，独立评分过程亦未得到记录核实。因此该核查仅作为有限的评分一致性与候选比较证据，不构成全量人工效度验证，也不构成对英文原文的直接验证。A2/A3 的原文链接仅覆盖部分记录，未链接记录不纳入原文层面的核验。在 24 条代表性样本上， Q_{eq} 与 Q_{huber} 对人工共识评分的 Spearman 相关均为 0.5667，两者相关差的配对 bootstrap 95% 区间为 $[-0.0590, 0.0623]$ ，跨零。据此，本文按接口一致性选择 Q_{huber} 作为主 *Q*，并以 Q_{eq} 进行敏感性分析，不将该选择表述为人工或统计验证的胜出。

污染敏感性另作一项检验。对 A1 的原文做逐记录的 Unicode 完整性审计，按窄口径（格式字符与除制表、换行外的控制字符）检出 428 条，按宽口径（并含私用区与非法码点）检出 463 条，分别占 51230 条的 0.836% 与 0.904%。题目材料的历史报告中曾出现 334 条这一计数，但现有扫描规则无法复现，故不作为本次结果引用。两套规则各自对应一组敏感性结果，将相应记录分别从阈值、权重、Huber 阈值与指标对排序的估计中剔除后：权重向量的 L_1 变化为 0.001002（窄）与 0.000788（宽）；权重排序的 Spearman 为 0.5274（窄）与 0.6550（宽）；Huber 阈值由 0.396554 变为 0.396452（窄）与 0.396442（宽）；各域高冲突阈值的最大位移出现在 book 域（ -0.001438 ），其余域在 $\pm 3 \times 10^{-5}$ 量级；231 个指标对的宏平均排序 Spearman 为 0.99978。两组规则下的结论一致。

权重排序的秩相关较低（0.53 与 0.66）源于权重本身的分布形态：22 个指标的权重密集在 0.0451–0.0455 的窄区间内，任何微小扰动都会改变其相对次序，而权重的实际数值变化极小（ L_1 变化约 10^{-3} ），对评分的影响可以忽略。相比之下，阈值与指标对排序几乎不动，且检出的记录中确有更大比例落在冲突上尾——book 域被剔除的 17 条里有 11.76% 超过主阈值，而基线为 5%。基于这一结果，本文保留全部记录并报告其影响，而不作删除；在无法确认成因的前提下，删除记录会引入新的偏差。

二次面的表现亦予报告，但不作事后改选。其嵌套 CV 宏平均标准化 RMSE 为 0.58901，优于主模型的 0.63305，检验集 R^2 也更高（0.6817 对 0.6189）。但 153 个系数由 512 条配方估计，且不区分结构零与舍入零（511/512 行含零），过拟合风险明确。按选模纪律，主模型在选模阶段即已冻结，不允许在看到检验集结果后更改，故二次面仅作敏感性对照保留。域序对预处理场景的稳健性见图 5.18。




图 5.18 A1 七域排序在预设场景下的稳健性

5.6 本章小结

本问的三项交付如下。质量评分方面，22 个指标经 A1 单点校准的方向统一后合成两个候选，等权候选的 A1 宏平均为 0.49622 (95% 区间 [0.49491, 0.49763])，稳定性加权 Huber 候选为 0.49848 ([0.49657, 0.50043])，后者按接口一致性选为操作主分；A2/A3 与 A1 的同域差值四个区间全部跨零，点估计均在千分位以下。冲突分析方面，22 个指标构成 231 对，A1 各域的中位冲突度在 0.2712–0.4382 之间，最高的指标对为 `dsir_math` 与 `rps_doc_unigram_entropy` (0.5993)，消解采用稳定性加权 Huber 位置。配比建模方面，单纯形岭回归在 A4/A5 交叉验证上以 0.39860 略优于参考分量 OLS，同尺度检验集 A6/A7 的 $R^2 = 0.6189$ 、 $\text{Spearman} = 0.8327$ ，136 个域对中 106 对有足够份额支持 10 个百分点替代。

本问的结论受三条限制约束。第一， Q 是受限候选分：30 条小样本人工核查的评审间一致性为 $\kappa = 0.765$ 、 $\text{Spearman} = 0.806$ ，但该核查不能区分两个候选，故主分的确定属接口一致性选择而非效度验证的胜出，793 条规模的全量人工评分未实施；另有 7 个 `rps_*frac*` 字段的上游生成公式未追溯，整体剔除后 A1 样本分的 P95 绝对差达 0.113048，本文以该场景作为语义不确定性的上界探测。第二，配比模型不具备跨尺度定量外推能力，60M 与 1B 上的 R^2 转负 (−7.93 与 −810.12)， Spearman 仍保持 0.73–0.83，可用的只是同尺度内的排序而非跨尺度预测。第三，配比域比损失目标多 4 个，这 4 个域的损失不可观测，是模型的结构性限制。

本问交付给问题二的是质量评分 Q 的可比尺度 ($[0, 1]$)，A1 七域宏平均 0.498478，版本 Q1-q_huber-v1) 与 17 维配比 π 的单纯形定义，问题二须在此基础上构造含 N 、 D 、 Q 、 π 的广义标度律。

6 问题二的模型建立与求解

6.1 问题二分析

本问要求把数据质量 Q 与领域配比 p 显式纳入标度律，在经典形式 $L(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 之外构造同时含 N 、 D 、 Q 、 p 的广义关系，并据此分析各因素的边际效用与弹性、讨论领域之间的替代与互补、推导质量提升与规模扩大可相互替代的条件，最后完成参数估计与检验。按题目规定，附件 A 的信息经问题一输出的 Q 与 p 引入，本问不重复读取 A 的原始文件；直接使用的数据为附件 B 的 B1–B12，其中 B11 与 B12 为辅助。问题一交付的 Q 取值于 $[0, 1]$ ，A1 七域宏平均为 0.498478；配比 p 为 17 维单纯形向量（问题一记作 π ，本问沿用题目记号 p ）。

本问的真正困难不在拟合，而在识别。附件 A 与附件 B 是两组相互独立的实验，二者都以交叉熵损失为可观测量，题目要求参赛队伍提出可检验的假设把两组规律统一到同一模型中；换言之，”两组的 Loss 处于同一量尺”本身是一个必须检验的前提，而不是可以默认的事实。同时， Q 与 p 在本数据上并非自由变化的两个变量：问题一的诊断已经表明，依据配比派生出的质量特征是 p 的确定性函数，若把它与 p 并列放进回归，形如 $p^\top b + \theta Q$ 的模型在 $p^\top(b + \theta \tilde{Q})$ 的意义下不可分别识别。配比一侧同样受限：附件 B 的各来源表中没有可逐行追溯到具体训练运行的 17 维配比向量，因此 p 的边际效应无法从 B 组数据直接估计。

本问的输出有三项，供问题三使用：经典分支的五个标度律参数及其不确定性、各因素的弹性，以及质量基线的取值 Q_0 。问题三在算力约束下分配资源时， L 对 N 、 D 的响应取自本问冻结的参数， Q 的提升成本与收益则以本问的弹性结构为参照。

6.2 模型建立

6.2.1 广义标度律的嵌套形式

质量与对比对损失的作用通过”有效数据量”进入模型。记

$$L = E + AN^{-\alpha} + BD_{\text{eff}}^{-\beta}, \quad D_{\text{eff}} = D \exp\{h(Q, p)\} \quad (6.1)$$

式中， E 为不可约损失， A 与 α 刻画参数量方向的衰减， B 与 β 刻画数据量方向的衰减， D_{eff} 为把数据质量与领域配比折算之后的等效数据量， h 为折算函数。对 h 施加参考态约束

$$h(Q_{\text{ref}}, p_{\text{ref}}) = 0 \quad (6.2)$$

使模型在参考状态处精确退化为经典形式。这条约束的作用是保证广义模型是经典的严格扩展而非替换：当数据质量达到参考水平且配比取参考配方时，模型必须回到 $L =$

$E + AN^{-\alpha} + BD^{-\beta}$ ，否则两套结果无法互相校验。取参考质量为 $Q_{\text{ref}} = 1$ ，则 $Q \rightarrow 1$ 时 $h \rightarrow 0$ ，模型退化为经典形式；这一退化是设计出来的性质，不是拟合得到的实证结论。

h 的分量按可识别性由少到多排列，构成同一族内的三个嵌套模型：

$$\text{M0} : h = 0; \quad \text{M1} : h = g_p(p); \quad \text{M2} : h = g_p(p) + g_Q(Q) \quad (6.3)$$

式中，M0 为经典参考分支，M1 在配比方向增加一个增量，M2 再叠加质量方向的增量。嵌套的意义在于：只有当前一层已能识别，后一层的新增系数才有解释；若跳过 M1 直接拟合 M2，则 g_Q 吸收的可能是配比未能解释的部分，其系数不能读作质量效应。

考虑 h 只含质量项的最简可拟合形式，取 $g_Q(Q) = \gamma \log Q$ ，此时 $D_{\text{eff}} = D Q^\gamma$ ，模型化为

$$L = E + AN^{-\alpha} + BD^{-\beta}Q^{-\kappa}, \quad \kappa = \gamma\beta \quad (6.4)$$

该形式在 $Q = 1$ 处退化为经典形式，且弹性具有封闭表达式，便于后续推导替代条件。本文在附件 B 的质量数据上估计这一形式，其证据等级见 6.5。

6.2.2 边际效应与弹性的定义

题目要求分析各因素的边际效用与弹性，二者不是同一个量。边际效用是损失对自变量的偏导数，带量纲；弹性是无量纲的相对变化率：

$$\frac{\partial L}{\partial x} = \begin{cases} -\alpha AN^{-\alpha-1}, & x = N \\ -\beta BD^{-\beta-1}Q^{-\kappa}, & x = D \\ -\kappa BD^{-\beta}Q^{-\kappa-1}, & x = Q \end{cases} \quad \varepsilon_x = \frac{\partial L}{\partial x} \cdot \frac{x}{L} \quad (6.5)$$

式中， ε_x 为因素 x 的弹性，含义是 x 增加 1% 时 L 变化的百分比。采用无量纲弹性而非边际导数的理由有二：其一， N 、 D 、 Q 的量纲与量级完全不同，边际导数之间不可直接比较，无法回答“同样多花一块钱投在哪一项更划算”；其二，题目要求推导质量与规模可相互替代的条件，而替代关系由等损失曲线给出，其斜率正是两个边际导数之比，用弹性表达才具有跨量级的可比性。 L 随 N 、 D 、 Q 增大应单调下降，故三个弹性在参数为正时应全为负号；符号若为正，应先怀疑计算有误。

由等损失条件可直接得到替代关系。令 $dL = 0$ ，在固定 D 的条件下有

$$\left. \frac{dN}{dQ} \right|_L = -\frac{\partial L / \partial Q}{\partial L / \partial N} = -\frac{\kappa N}{\alpha Q} \cdot \frac{AN^{-\alpha}}{BD^{-\beta}Q^{-\kappa}} \quad (6.6)$$

式中，右端第一个因子是弹性的比值，第二个因子是两个衰减项之比。该式给出“质量提高一个单位需要以多少参数量作为代价”的连续形式，其数值含义在 6.4 中以有限增量的方式报告。

6.3 模型求解

求解分四步：数据审计、参数估计、不确定性量化与外推检验。数据审计先行，用于确认各附件在本次建模中的角色与支持范围，避免把同名但不可比的记录混入拟合。审计覆盖输入文件清单、角色契约、轨迹映射与设计支持四项，共 36 项检查全部通过。B1 共 1176 行，按 B12 的检查点索引映射为 8 条完整的 Pythia 训练轨迹，每条轨迹 147 个检查点；配比列在 B1 中为空。这里必须强调，1176 是检查点数而非独立实验数，8 条轨迹才是独立的抽样单元，后续所有区间估计均按轨迹整簇重抽样。

参数估计在 B1 上用有界非线性最小二乘完成，约束为 $0 \leq E < \min(\text{val_loss})$ 与 $A, \alpha, B, \beta > 0$ 。为避免陷入局部极小，取 24 组固定初值做多重启动，以目标函数最小的解为最终估计。不确定性用整轨迹整簇 bootstrap 量化：每次有放回地从 8 条完整轨迹中抽取 8 条，保留其全部 147 个检查点后重新拟合，重复 1000 次。按整簇而非按行重抽样是必要的，因为同一轨迹内相邻检查点的损失高度相关，按行抽样会把序列相关误当作独立信息，从而严重低估区间宽度。外推检验采用留一规模法：每次留出一条完整的 147 点轨迹，用其余 7 条重新拟合后预测被留出的轨迹。B1 的设计支撑见图 6.1：8 个参数量取值与 147 个训练检查点构成交叉设计，同一 D 网格在各 N 列之间水平对齐，这正是 α 与 β 能够分别识别、且缩放雅可比条件数只有 56.378 的原因；图中同时给出了该拟合所依赖的支持边界 ($N \leq 11.965825B$ 、 $D \leq 299.893B$)，后文讨论 B9/B10 外推时反复引用这两个上界。求解步骤见表 6.1。

表 6.1 经典标度律的参数估计与不确定性量化步骤

步骤	操作
1	审计附件角色与支持域，确认 B1 为唯一拟合数据、B2–B5 为验证数据
2	按 B12 检查点索引把 B1 的 1176 行映射为 8 条完整轨迹
3	for 24 组固定初值 do 有界非线性最小二乘，记录目标函数值
4	取目标函数最小的解为冻结参数 $\hat{E}, \hat{A}, \hat{\alpha}, \hat{B}, \hat{\beta}$
5	for $b = 1$ to 1000 do 按轨迹整簇重抽样并重新拟合
6	由 1000 组重抽样解取百分位区间，得各参数的 95% 区间
7	for 每条轨迹 do 留出该轨迹全部 147 点，用其余轨迹重拟合并预测
8	在 B2–B5 上按来源分别计算误差，不合并、不重调参




图 6.1 B1 的设计支撑：8 个参数量取值与 147 个训练检查点构成的交叉设计，颜色为观测验证损失。同一数据量在各规模列之间水平对齐，是 α 与 β 可分别识别的依据；点云的外沿即该拟合的支持边界

6.4 结果分析

6.4.1 经典分支的参数与拟合优度

经典分支 M0 的参数估计与区间见表 6.2。五个参数在 1000 次整轨迹 bootstrap 下的区间都很窄，这是 8 条轨迹所覆盖的 N 、 D 跨度较宽、且设计点近似正交的直接结果；但区间的可靠性受簇数限制，只能作为稳定性提示（见 6.5）。

表 6.2 经典标度律 $L = E + AN^{-\alpha} + BD^{-\beta}$ 在 B1 上的参数估计

参数	估计值	95% 区间下界	95% 区间上界
E	1.689798	1.689645	1.689962
A	0.353980	0.353843	0.354125
α	0.339977	0.339831	0.340115
B	1.240306	1.240160	1.240434
β	0.279878	0.279823	0.279937

拟合在 1176 个检查点上的内样本指标为： $\text{RMSE} = 1.4650 \times 10^{-4}$ ， $\text{MAE} = 1.0523 \times 10^{-4}$ ，最大绝对误差 $= 9.2038 \times 10^{-4}$ ， $R^2 = 0.99999982$ ， $\text{Spearman} = 0.99999965$ 。缩放雅可比矩阵满秩 (5/5)，条件数为 56.378，远低于病态告警阈值，说明五个参数在该设计下不存在

共线退化；24 组初值全部收敛，最优解之间的最大相对参数跨度为 4.46×10^{-10} ，可排除初值敏感性。需要明确的是，这些是拟合内指标， R^2 接近 1 只说明经典形式在 B1 支持域内能忠实描述损失随 N 、 D 的变化，不构成模型正确性的外部证据；外部证据由 6.5 的分来源验证承担。

留一规模检验的结果同样紧凑：留出 12B 轨迹时 RMSE 为 1.0198×10^{-4} ，留出 70m 轨迹时为 2.2023×10^{-4} ，八条轨迹的留出 R^2 介于 0.99999923 与 0.99999983 之间，秩相关均为 1.0000。误差在小规模端更大，这与幂律模型在小 N 端曲率更强的特性一致。

拟合优度接近 1 的数值应当有对应的诊断支撑，否则读者无从判断残差是否只被均值掩盖。图 6.2 给出残差对拟合值的散布：残差均值为 $+2.6 \times 10^{-14}$ ，即经典形式不存在系统性偏倚；残差标准差为 1.47×10^{-4} 。但残差的离散程度随损失水平上升而扩大——拟合值在 2.0 至 2.5 之间的 760 个点几乎全部落在 $\pm 2 \times 10^{-4}$ 以内（极值 $\pm 3.8 \times 10^{-4}$ ），拟合值超过 3.0 的 58 个点则扩展到 $[-6.5 \times 10^{-4}, +9.2 \times 10^{-4}]$ 。全样本只有 1 个点的绝对残差超过 7×10^{-4} 。这是异方差而非偏倚：它不否定参数的估计，但提示该模型的误差并非同分布。这一点在问题三按预算筛选候选点时不影响排序，因为筛选依据的是预测值本身而非区间宽度。




图 6.2 B1 的残差结构：残差均值约为零（无系统偏倚），但离散度随拟合损失上升而扩大（异方差）

6.4.2 边际效应与弹性

在 B1 的中位点（ $N = 1.2285B$ 参数、 $D = 146.80B$ token，预测损失 2.3268）处，各因素的边际效应与弹性为：

两个弹性均为负，与“损失随规模增大而下降”的先验方向一致。数值上，参数量的弹

表 6.3 B1 中位点处的边际效应与弹性（括号内为 95% 整轨迹 bootstrap 区间）

因素	量纲	边际效应 $\partial L/\partial x$	弹性 ε_x
参数量 N	每 +1B 参数	-0.091339	-0.048225
数据量 D	每 +1B token	-5.8526×10^{-4}	-0.036924

性绝对值略大于数据量（0.0482 对 0.0369），即在该工作点上增加同等百分比参数量带来的损失下降更多。这一比较必须限定在中位点附近：弹性本身随工作点移动，不是常数。

逐规模的弹性见表 6.4，其中 ε_N 与 ε_D 呈现方向相反的趋势。

表 6.4 八条轨迹的 N 弹性与 D 弹性中位数

模型规模	70m	160m	410m	1b	1.4b	2.8b	6.9b
ε_N	-0.1033	-0.0841	-0.0659	-0.0506	-0.0463	-0.0378	-0.0287
ε_D	-0.0300	-0.0324	-0.0347	-0.0366	-0.0372	-0.0382	-0.0394
模型规模	12b						极差
ε_N	-0.0241						[-0.1033, -0.0241]
ε_D	-0.0400						[-0.0400, -0.0300]

ε_N 从 70m 处的 -0.1033 单调减弱到 12b 处的 -0.0241，即模型越大，参数量翻倍带来的相对收益越小； ε_D 则从 -0.0300 增强到 -0.0400。两条曲线在中段（约 1b 附近）交叉。这一结构提示：在小规模端扩大参数量更有效，在大规模端继续增加训练数据的相对回报更高，与 Chinchilla 关于“参数量与数据量应同比例增长”的经验结论方向一致，但本文给的是同一模型族内的连续弹性和交叉位置，而非最优配比本身。边际效应 $\partial L/\partial D$ 在八条轨迹上完全相同（均为 -5.8526×10^{-4} ），因为 M0 形式中该项只依赖 D 而不依赖 N ，这是该函数形式的结构性含义而非拟合巧合。

比较两个弹性的变化来源时可以看到一个不对称： ε_D 沿单条轨迹随训练推进的跨度（p10 至 p90）达 0.1142，而八条轨迹的中位数之间只相差 0.0100，相差一个量级。也就是说， D 弹性的主要变化来自“训练进行到哪一步”，而不是“模型有多大”；前者在图 6.4 的面板 (b) 中体现为灰棒的长度，后者只表现为八个点位的水平位移。这一区分对问题三有直接含义：在预算分配中若把 ε_D 当作与训练进度无关的常数使用，会引入远大于规模间差异的误差。

边际效应与弹性的完整轨迹见图 6.3 与 6.4。两图中的区间均来自问题二的 1000 次整迹 bootstrap；其中 $|\partial L/\partial D|$ 的区间半宽最大不足坐标跨度的 0.1%，在纸面上窄于线宽，故未单独填色绘出，改以文字标注，以免留下一条读者看不见的置信带。




图 6.3 两个规模方向的边际效应：(a) $|\partial L/\partial N|$ 随模型规模的变化；(b) $|\partial L/\partial D|$ 随训练数据量的变化

上两图把弹性汇总到规模这一维，看不到它在单条轨迹内随训练推进的完整形状。图 ?? 按 N 分面给出两个弹性沿 D 的剖面，每个主图下方另附一条放大窄条，把 95% 区间相对估计值的偏差按其真实尺度展开。剖面显示出两点汇总图看不到的结构：其一，两个弹性随 D 单调变化且八个规模上的形状一致，说明这种依赖来自 M0 的函数形式而非某个规模的偶然；其二， ε_D 的区间带在小 D 端明显张开、随 D 增大而收拢，即训练 token 越多，该弹性的估计越稳定。需要与图 6.4 并读：后者画的是逐轨迹中位数与 p10–p90 跨度，前者画的是沿 D 的完整曲线，因此前者在小 D 端会低到后者 p10 以下——两者口径不同，不是相互矛盾。

6.4.3 质量与规模的等损失兑换条件

题目要求回答“质量提升 0.1 等价于参数增加多少”。该条件在 $h = g_Q(Q) = \gamma \log Q$ 的设定下可直接由 6.4 的等损失关系解出。用于估计 Q 方向的系数时，附件 B 中只有 B6 与 B7 含有质量维度，且二者按《数据说明》均为基于真实标度律校准并叠加噪声的半合成数据，不是直接实验观测。在这两组数据上拟合 $L = E + AN^{-\alpha} + BD^{-\beta}Q^{-\kappa}$ ，得

式中，“相对 M0 改善”一列为同一半合成网格上含质量项与不含质量项两个模型的留一 Q 水平 RMSE 对照，含质量项的模型误差更低，说明半合成网格确实携带了 Q 方向的信号。取共同网格中心 ($N = 1\text{B}$ 、 $D = 150\text{B}$ 、 $Q = 0.6$) 为工作点，把 Q 提高 0.1 后维持




图 6.4 两个无量纲弹性随模型规模的变化。上排为全尺度: (a) ε_N 、(b) ε_D , 圆点为轨迹中位数, 灰棒为同一轨迹内检查点的 p10-p90 跨度; 下排 (c)(d) 把 95% 整轨迹 bootstrap 区间以各点自身的中位数为零点放大显示——该区间仅占纵轴跨度的 0.07% 与 0.14%, 在全尺度图中窄于线宽而不可见

表 6.5 B6/B7 半合成数据上的质量指数估计

数据集	行数	κ	$\gamma = \kappa/\beta$	ε_Q 中位数	留一 Q 水平 RMSE	相对 M0 改善
B6	360	0.085033	1.216453	-0.054048	0.089840	0.145135
B7	450	0.098000	1.179775	-0.052055	0.084316	0.129540

表 6.6 Q 提高 0.1 的等损失参数量兑换 (工作点 $N = 1B$ 、 $D = 150B$ 、 $Q = 0.6$)

数据集	兑换前的 N	兑换后的 N	参数量变化 ΔN
B6	1.000000B	0.878085B	-0.121915B
B7	1.000000B	0.881795B	-0.118205B

损失不变所需的参数量为




图 6.5 冻结 M0 下两个弹性沿训练数据量的剖面（按参数量分面）。主图为真实弹性尺度；每个主图下方的窄条把 95% 整轨迹 bootstrap 区间相对估计值的偏差放大显示，单位为 10^{-5} ，未改变原始区间。区间基于 8 条完整 Pythia 轨迹，独立轨迹数偏少，仅作稳定性提示；弹性是冻结 M0 的模型蕴含量，不代表配比或质量的效应

即在给定的工作点上，质量评分每提高 0.1，可替代约 0.12B 参数量，相当于原参数数量的 12%。方向与量级在两组半合成数据上一致（ $-0.1219B$ 与 $-0.1182B$ ），这是该结论中唯一可比对的一致性证据。

该数值的解释必须限定在四重边界之内。其一，它来自半合成拟合曲面，是对照数据说明允许的补充分析，不能表述为真实训练观测，也不是实际训练中的资源替代率。其二，它衡量的是等损失关系而非等算力或等成本关系——提高质量本身需要额外算力，该成本由问题三的成本函数处理，本处未计入。其三， Q 在 B6/B7 中是半合成网格自带的评分列，其量尺与问题一交付的 Q 是否一致尚无证据，故 $-0.12B$ 这一兑换率不能直接叠加到问题一的 Q 刻度上使用。其四，B7 与 B6 的重合部分为 360/360 行且损失改动为零，二者不是独立重复实验；另一份含质量维度的 B8 在固定 N 、 D 后与 B6/B7 方向相反，在未取得可验证的生成规则之前本文不把三份数据合并估计单一质量弹性。因此本表只作为条件性示例报告，不进入任何后续优化目标。

这一方向冲突不宜只以文字断言，其图证见图 6.5。在控制了 N 与 D 的匹配单元内逐单元估计 Loss 对 Q 的斜率，B6 的 45 个单元与 B7 的 45 个单元全部为负，而 B8 的校准部分 90 个单元与外推部分 60 个单元全部为正，无一例外；两个方向的中位斜率分别为 -0.3409 、 -0.3393 与 $+2.0279$ 、 $+1.8105$ ，池化 Spearman 相关为 -0.324 、 -0.299 与 $+0.933$ 、 $+0.966$ 。符号完全分离意味着这不是噪声导致的方向不定，而是两组数据在生成层面就不同——这正是本文坚持不合并估计、并把质量弹性限定为条件性示例的直接理由。




图 6.6 匹配 N - D 单元内 Loss 对 Q 的斜率符号分布：B6/B7 的 90 个单元全为负，B8 的校准与外推共 150 个单元全为正，两组方向完全分离

6.4.4 大尺度外推情景

题目要求结合 B9、B10 讨论百亿参数以上的外推。B10 为按已拟合标度律估算的损失表，不是独立观测，其 128 行模型的参数量全部超出 B1 的支持上界 (11.965825B)，其中 102 行的数据量也超出 B1 的 D 支持上界 (299.893B)。把冻结的 M0 参数直接代入 B10 的 N 、 D ，得预测损失中位数 1.90642，范围 [1.78384, 4.08630]；把 1000 组 bootstrap 参数逐一代入，区间的中位宽度仅 1.590×10^{-4} 。区间的窄是参数不确定性小的结果，不表示外推可靠：该区间只传播了参数变异，未包含跨评测协议的损失偏差、模型形式错设与远距离外推误差。偏差最大的几行集中在数据量极小的一端（如 $D = 0.1B$ ），属于 B1 支持域外的低端外推。因此本节只用于量级与不确定性的讨论，不报告任何合并误差分数，也不声称外推通过验证。

6.5 模型验证与灵敏度分析

6.5.1 分来源验证

验证按 B2–B5 逐来源进行，不做任何合并，也不在验证集上重调参。合并本身是不成立的：四个来源的数据角色与评测协议互不相同，题目对 B2 明确标注为半合成，B3 是同来源轨迹的插值构造，B4 与 B5 为文献汇编数据。各来源的验证指标见表 6.7。

表 6.7 B2–B5 的分来源验证指标（不合并、不重调参）

来源	性质	n	RMSE	R^2	Spearman	最大绝对误差
B2	半合成压力测试	1029	1.243085	−5.072799	0.788102	3.511705
B3	同来源轨迹插值	4000	0.003821	0.999958	0.999990	0.014734
B4	跨族文献数据	57	0.292667	0.604505	0.982982	1.047711
B5	文献标度律数据	44	0.197595	0.730559	0.958808	0.450838

四个来源给出四类不同的判读，不能压成一个结论。B3 的误差极小，但它是 Pythia 轨迹的插值构造，与 B1 共享来源结构与数据生成过程，4000 个点不是 4000 个独立实验；这一结果说明 M0 能跟随同来源轨迹内的变化，不构成外部效度证据。B2 的 R^2 为负，说明在跨模型族的半合成情景下，B1 拟合的绝对水平发生系统性偏移；这正是半合成压力测试应当暴露的问题。B4 与 B5 的误差介于两者之间，但它们的绝对量值能否与 B1 比较本身尚不成立，原因见下。

6.5.2 损失量尺的可比性审计

前一小节隐含一个必须显式检验的前提：B4、B5 记录的损失与 B1 的验证损失处于同一量尺。本文对三个来源的损失协议逐项审计，比对内容包括损失名称、单位、评测数据集、数据划分、分词器、上下文长度与预处理，结论见表 6.8。

表 6.8 各来源相对 B1 的损失量尺可比性分类

来源	相对 B1 的分类	来源内趋势	可用范围
B4	不可比	未知	仅作描述
B5	不可比	不可比	不构成正式外部验证

全部 25 个来源组相对 B1 均为不可比，达到”绝对可比”等级的记录数为 0。两处具体发现值得记录。其一，B4 中标为 Cerebras-GPT 的 7 行全部记录同一个数据量 $D = 2050B$ ，损失从 2.95 递减到 2.00；而 Cerebras 原论文给出的七个训练 token 终点与相应的 Pile 测试集交叉熵为

$$\underbrace{[2.2, 5.1, 11.8, 26.3, 53.0, 133.2, 257.1]}_{\text{训练 token 终点 (B)}}, \quad \underbrace{[2.608, 2.349, 2.181, 1.997, 1.834, 1.704, 1.572]}_{\text{Pile 测试集交叉熵}} \quad (6.7)$$

两者在数据量与损失上都不对应，故这 7 行不能作为已核实的 Cerebras 观测使用。其二，B5 中标为 Kaplan 等 2020 的 GPT-3 各行，其规模与 token 网格更接近 Brown 等 2020 的工作；在完成逐点核对之前本文保持原标签并存疑，不擅自改写来源。此外，Chinchilla 与 Gopher 使用不同的分词器，其记录也不能合并。B1 内部一致性的唯一正面证据是 $ppl \approx \exp(\text{val_loss})$ 在 1176 行上成立（最大绝对差约 0.0061，属字段舍入），这支持 B1 的损失为自然对数尺度，但不足以冻结完整评测协议。

这一审计的结论是方法论层面的：跨来源的损失数值在协议未对齐之前不可直接比较，因此本文不报告任何合并误差或”外部验证通过”的判定，而只报告各来源内可解释的误差与排序。这同时说明：题目要求的”提出可检验的假设把附件 A 与 B 统一到同一模型”，在本数据条件下的正确答案不是假定二者可比，而是把可比性本身作为一个受检验的门禁。

6.5.3 配比与质量的可识别性

p 方向的识别门禁结果为失败。审计逐表检查附件 B 各来源是否含有可逐行连接到损失记录的 17 维配比数值向量，结果为：已核验并连接成功的配比向量 0 个，可连接损失行 0 行，因此共线性检验不可执行（无可检对象），M1 未估计。失败的原因是结构性的：

B1 的 1176 行共享同一份训练数据配比，配比列本身不存在；B2 为半合成；B3 是 B1 轨迹的插值；B4 与 B5 为文献汇编，缺少行级的运行标识。B1–B5 中可直接对照的 17 维配比命名体系来自附件 A，其中 3 个与损失目标直接对应、3 个近直接对应、11 个为推断对应，可信等级不同，不能不加区分地传播。

此处需要给出代数上的解释，而不只是报告“数据不足”。在 M1 中，若所有观测共享同一固定配方 p_0 ，则 $h = g_p(p_0)$ 为常数， $B \exp[-\beta g_p(p_0)]$ 可整体并入 B ，模型化为

$$L = E + AN^{-\alpha} + B^*D^{-\beta}, \quad B^* = B \exp\{-\beta g_p(p_0)\} \quad (6.8)$$

即与 M0 在代数上同形。此时数据只能估计合并后的 B^* ，无法把配比的贡献与基线系数 B 分开。这不是精度问题而是可识别性问题：即使将来补齐了那个共同配方的数值，单一静态配方也只能确认配方身份，不能打开 p 的识别门。

Q 方向的门禁同样未通过，原因不同但同属可识别性。问题一的诊断表明，配比派生的质量特征 $Q_{\text{covered}}(p)$ 在其覆盖的 8 个场景中全部是 p 的确定性函数，没有任何一个场景提供独立于 p 的质量变化。当 $Q = q(p)$ 时，对任意函数 a ，变换

$$g_p^{\text{new}}(p) = g_p(p) + a(q(p)), \quad g_Q^{\text{new}}(Q) = g_Q(Q) - a(Q) \quad (6.9)$$

不改变任何观测到的 h ，因此预测总和无法唯一拆分为配比项与质量项。在 A 侧的实际比较也与此一致：把质量特征加入配比回归后，嵌套交叉验证的标准化 RMSE 由 0.595170 升至 0.763354，即加入质量项不但没有改善，反而变差，这与该特征只是配比的重参数化相符。配比的辨识度增量为 0，说明线性模型中质量项未提供独立于配比的信息。

A 侧配比模型本身的跨尺度表现见图 ??。它给出两件事：同尺度（1M）上 13 个目标的逐目标 RMSE 集中在 0.45 附近、宏平均 $R^2 = 0.619$ ；一旦换到 60M 与 1B 的跨尺度切分，逐目标点云整体上移，宏平均 R^2 分别跌到 -7.934 与 -810.1 。这与问题一在 A 侧得到的结论一致，本文在此处的用途只是说明：**本问不采用 A 侧配比模型的结果去推断 B 侧的配比效应**，因为该模型连跨尺度的数值外推都不成立，更没有理由假设它能迁移到另一批来源不同的实验上。这里的 13 个点不是独立训练重复，故不配置置信区间；该切分也不是新增盲测。

两条门禁的结论都必须准确表述：这是当前数据条件下的识别性限制，不是 p 或 Q 无效的证据。M1 与 M2 的状态记为未估计，而非估计为零。要重开这两道门，需要的是对 B 侧各训练运行可追溯的配比配置、能够在控制 N 、 D 与模型族之后仍有变异的多个独立配方，以及独立于配比的质量变化证据，三者缺一不可。本文按题目要求把这些前置条件作为后续工作的入口列出，而不在缺少证据时给出系数。




图 6.7 A 侧配比模型在同尺度与跨尺度切分上的逐目标表现：(a) 逐目标 RMSE；(b) 逐目标 R^2 (symlog 刻度，虚线为零参考)。点代表 13 个领域目标，菱形为其算术平均。点不是独立训练重复，故不配置区间；该切分不构成新增盲测，跨尺度表现只说明迁移限制，不证明 B 侧的配比效应

6.5.4 稳健性小结

除上述验证外，本文另做了两项诊断。其一为删项诊断，用于确认两个规模方向的必要性：去掉 N 项后 R^2 降至 0.5352578、RMSE 升至 0.2331907，去掉 D 项后 R^2 降至 0.4647400、RMSE 升至 0.2502578，二者均说明两个方向不可省略；该诊断只用于说明模型结构，不参与选型。其二为留一轨迹交叉验证，五折整轨迹分组下 $n = 1176$ 、RMSE = 1.5144×10^{-4} 、 $R^2 = 0.99999980$ ，2000 次重抽样的区间为 $[1.2563 \times 10^{-4}, 1.7918 \times 10^{-4}]$ 。

本问全部区间估计共同受一条限制：独立的轨迹簇只有 8 条。百分位区间对簇数敏感，因此上文的区间都应读作稳定性提示，而不是高精度总体区间。这一点在解释弹性差异时尤为重要—— ε_N 与 ε_D 的逐规模趋势在八条轨迹上单调且一致，但若要在更细的尺度上作比较，现有簇数不足以支撑。

6.6 本章小结

本问的交付如下。经典分支方面， $L = E + AN^{-\alpha} + BD^{-\beta}$ 在 B1 的 1176 个检查点上拟合得 $E = 1.689798$ 、 $A = 0.353980$ 、 $\alpha = 0.339977$ 、 $B = 1.240306$ 、 $\beta = 0.279878$ ，内样本 $R^2 = 0.99999982$ ；缩放雅可比满秩、条件数 56.378，24 组初值全部收敛，留一规模 RMSE 在 1.02×10^{-4} 至 2.20×10^{-4} 之间。弹性方面，中位点处 $\varepsilon_N = -0.048225$ 、 $\varepsilon_D = -0.036924$ ，逐规模呈 ε_N 减弱、 ε_D 增强并约在 1b 附近交叉的格局。替代条件方面，在半合成网格上，质量评分提高 0.1 约等价于 0.12B 参数量（B6 为 $-0.121915B$ 、B7 为 $-0.118205B$ ），该结

果只作条件性示例。

本问的结论受三条限制约束。第一，质量方向的系数来自半合成数据，不是实测观测，**B6** 与 **B7** 的样本大量重合、**B8** 方向相反，故不合并估计单一质量弹性。第二，配比方向的识别门禁失败，可连接损失的 17 维配比向量为 **0**，**M1** 未经估计；这不是配比无效的证据。第三，**B4** 与 **B5** 相对 **B1** 的损失量尺不可比，可比记录数为 **0**，因此本问不报告合并的外部验证指标，只报告分来源误差。

本问交付给问题三的是三个量：经典分支的五个参数与其不确定性、各因素的弹性结构，以及质量基线 $Q_0 = 0.498478$ 。问题三在此基础上构造算力约束下的资源分配模型；由于 p 与 Q 的独立效应在本问未获识别，问题三的联合优化须在证据支持的变量范围内进行，其处理方式见下一章。

7 问题三的模型建立与求解

7.1 问题三分析

本问在总算力预算 C 受限的条件下，在参数量 N 、数据量 D 、领域配比 p 与数据质量 Q 之间分配资源，并分析预算跨越不同量级时最优分配是否发生本质改变。算力消耗由三部分组成：基础训练开销 $C_{\text{train}} = 6ND$ 、数据质量提升开销 $C_Q = D[g(Q) - g(Q_0)]_+$ 与长文本注意力开销 $C_{\text{attn}} = \eta N D L_{\text{ctx}}$ ，其中 $\eta = 2 \times 10^{-4}$ 。上下文长度 L_{ctx} 由模型架构与任务需求外生给定，其可行取值须依据附件 C7，本题不把它作为内点寻优变量，但要求解析给出使注意力开销与训练开销相当的临界长度，并在其可行取值上完成敏感性分析。题目建议考察 10^{19} 、 10^{22} 、 10^{24} FLOPs 三档预算，并至少覆盖三个不同量级。

本问的困难有三处。第一，质量成本函数的量纲与量级需要先固定下来，否则约束的可行性判断无从谈起：三种候选 $g(Q)$ 在同一 Q 上的取值可相差一个量级以上，这会直接改变哪些 Q 是负担得起的。第二，按问题二的审计结论，配比的独立效应与质量的独立效应在当前数据下均未获识别，因此把 p 或 Q 当作由数据驱动的内点决策变量是没有依据的；本问必须在“哪些量可以寻优、哪些量只能固定”这一点上给出明确交代，而不是先在形式上写一个四变量优化、再悄悄把两个变量固定。第三，题目要求判断“结构性转移”，这需要一个可证伪的定义：若只凭图形观察就宣称策略发生了质变，结论无法复核。

7.2 模型建立

7.2.1 优化模型与变量域

记决策向量为 (N, D, Q, p) ，目标为最小化问题二冻结模型给出的预测损失：

$$\min_{N, D, Q, p} \hat{L}_{M0}(N, D) \quad \text{s.t.} \quad C_{\text{train}} + C_Q + C_{\text{attn}} \leq C \quad (7.1)$$

式中各项为

$$C_{\text{train}} = 6ND, \quad C_Q = D[g(Q) - g(Q_0)]_+, \quad C_{\text{attn}} = \eta N D L_{\text{ctx}} \quad (7.2)$$

其中 $[\cdot]_+ = \max(\cdot, 0)$ ， Q_0 为问题一交付的质量基线。可行性区域为 $N > 0$ 、 $D > 0$ 、 $Q_0 \leq Q \leq 1$ 、 $p_i \geq 0$ 且 $\sum_i p_i = 1$ 。质量一侧只允许提升而不允许下降，这一限制来自 $[\cdot]_+$ 的增量成本约定：若不设下界，优化器会把低于基线的质量当作零成本选项，从而给出一个以降低质量为代价换取更多参数的解，这在题意上不成立。

变量 p 的处理需要一个明确交代。题目允许把 p 作为联立决策变量，也可以由前两问结果确定，但须说明理由。本文不把 p 作为决策变量，理由是问题二的识别性审计：附件 B 中可逐行连接到损失的 17 维配比向量为 0 个， p 对损失的经验响应面不存在，模型 $M0$ 本身也不含 p 项。在这样的证据条件下把 p 写进决策向量，等价于对 $\partial L / \partial p$ 赋予一个未经

估计的数值，得出的”最优配比”只是该假设的算术推论，不具备可验证性。因此本文在固定 $Q = Q_0$ 、不含 p 的受限模型上求解，并把这一范围的边界在结果中显式标出。

7.2.2 质量成本函数与临界上下文长度

题目附录 B 给出三种 $g(Q)$ 及其参数，本文原样采用：

$$g_{\text{exp}}(Q) = \gamma e^{\lambda Q}, \quad g_{\text{pow}}(Q) = \gamma Q^\lambda, \quad g_{\text{log}}(Q) = \gamma \ln(1 + \lambda Q) \quad (7.3)$$

式中，指数型的 $\gamma = 10^7$ 、 $\lambda = 6.0$ ；幂函数型的 $\gamma = 5 \times 10^9$ 、 $\lambda = 4.0$ ；对数渐进型的 $\gamma = 2 \times 10^9$ 、 $\lambda = 10.0$ 。三种形式的形状差异决定了质量成本随 Q 上升的快慢，是题目要求比较的对象。

临界上下文长度可由两项开销之比直接解出。记 $C_{\text{attn}}/C_{\text{train}} = \eta L_{\text{ctx}}/6$ ，令其等于 1，得

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 30000 \quad (7.4)$$

式中， $L_{\text{ctx}}^{\text{crit}}$ 为注意力开销与训练开销相等的上下文长度。当 $L_{\text{ctx}} < 30000$ 时训练开销占优，大于该值时注意力开销占优，且比值等于 $L_{\text{ctx}}/30000$ 。该结果是题面成本公式的代数推论，不依赖任何拟合参数，也不依赖 Q 的取值，因而可作为纯解析结论使用。

7.2.3 结构性转移的定义与识别方法

题目要求给出结构性转移的”明确数学定义与识别方法”。本文把转移定义在相邻情景对之间：相邻指预算取相邻档位而上下文长度固定，或上下文长度取相邻档位而预算固定。对每一对情景，记录其活动约束集合与成本份额向量

$$s = (s_{\text{train}}, s_Q, s_{\text{attn}}), \quad s_j = \frac{C_j}{C_{\text{train}} + C_Q + C_{\text{attn}}} \quad (7.5)$$

并定义份额转移量

$$T = \frac{1}{2} \sum_j |s_j^{(b)} - s_j^{(a)}| \quad (7.6)$$

式中， T 为两个情景之间成本份额向量的总变差距离，取值于 $[0, 1]$ 。判定规则为：把问题二的参数不确定性按整轨迹 **bootstrap** 传播到两情景的选择上，若活动约束集合的改变在 **bootstrap** 中的发生概率不低于 0.95，或 T 的第 5 百分位超过数值误差带 ϵ_{num} ，则判该对情景之间存在结构性转移。 ϵ_{num} 定义为同一情景下按常规与更严格两种求解容差各算一次所得的 T 的最大值，两组容差须在运行前登记，使判据不受事后调参影响。各 (Q_0, g) 组合分别判定，全部组合一致才算”稳健转移”，否则记为”条件性转移”。这条规则的意义在于把”质的变化”从图形判断变为可复核的统计判据；在参数 **bootstrap** 缺失时，规则明确要求只报告描述性变化而不作转移判定。

7.3 模型求解

求解在冻结的 B1 实测网格上进行，不做连续松弛：候选点为问题二审计确认的 1176 个 (N, D) 组合，即 8 个参数规模与 147 个训练检查点的全部组合。选择离散网格而非连续变量，是为了避免求解结果越出 B1 的支持范围——若允许 N 、 D 连续取值，模型会外推到未观测区域，而问题二已经表明该模型不具备跨尺度外推能力。计算全部使用精确有理数运算，先把以十亿为单位的 N_B 、 D_B 还原为整数绝对量，再计算三项开销，避免浮点误差在 (10^{24}) 量级上的累积。平局时按预测损失、总成本、参数量、数据量、记录编号依次排序，使选择唯一确定。

上下文长度取 C7 中实际出现的五个离散值，即 2048、4096、8192、32768 与 131072，与三档预算交叉得到 15 个情景。为评估选择对参数不确定性的敏感性，把问题二保存的 1000 组整轨迹 bootstrap 参数逐一代入，在每个情景下重新筛选可行点并重新选择最优，记录选择频率与预测损失的百分位区间。

质量一侧的求解分两支。主支固定 $Q = Q_0$ ，此时 $[g(Q_0) - g(Q_0)]_+ = 0$ ，故 $C_Q \equiv 0$ ，预算全部由训练与注意力两部分消耗。由于 Q 不影响损失也不产生成本，三种 $g(Q)$ 在本支中不参与选择——这是一个必须说明的结果，而不是遗漏。作为独立的一支，本文另计算从 Q_0 到 $Q = 1$ 的纯质量成本曲线，用于回答“把质量提升到某个水平需要多少算力”。

第三支是条件性的质量—损失响应模型。记质量响应系数为 β_Q ，

$$L_{\text{cond}}(N, D, Q | \beta_Q) = \hat{L}_{M0}(N, D) - \beta_Q (Q - Q_0), \quad \beta_Q \geq 0 \quad (7.7)$$

式中， β_Q 为质量每提升一个单位所对应的损失下降。问题二未识别出该系数，故本文不为它赋任何估计值，而是把它作为自由参数扫描：对每个情景，在剩余预算内把 Q 提升到可负担的最大值，得到不同 N 、 D 组合关于 β_Q 的下包络，再报告包络发生切换的 β_Q 取值，即首次发生 N 或 D 重分配的阈值。这一支回答的是“若质量响应达到多大，资源配置才应当改变”，属于条件性结论。

7.4 结果分析

7.4.1 上下文长度的可行取值

C7 的审计覆盖 45 个模型架构记录，45 条记录的名称唯一、上下文取值均为正整数且无缺失，共得到 5 个离散长度，分布见表 7.1。

45 个模型中有 12 个 (26.7%) 的架构上限超过临界长度 30000，33 个不超过。这一分布说明长上下文在大模型架构中已是常见配置，但并非主流：超过临界值的模型占比约四分之一，其中最长的 131072 使注意力开销达到训练开销的 4.37 倍。需要说明的是，C7 记录的是 `max_position_embeddings`，即架构支持的上下文上限，不保证等于实际部署时使用的窗口；本文按题面要求以该字段确定可行取值集合，其与实际任务窗口的一致性需由

表 7.1 附件 C7 的上下文长度分布及其相对临界长度的位置

最大位置嵌入数	模型数	注意力/训练开销比	相对临界长度
2048	18	0.0683	低于
4096	8	0.1365	低于
8192	7	0.2731	低于
32768	11	1.0923	高于
131072	1	4.3691	高于

题目设定支持。该分布见图 7.1。




图 7.1 C7 上下文长度的分布与临界长度 30000 的位置（横轴为对数刻度）

7.4.2 预算与上下文交叉下的参考配置

固定 $Q = Q_0$ 时 $C_Q = 0$ ，约束退化为 $ND(6 + \eta L_{\text{ctx}}) \leq C$ ，即在给定上下文长度下，可负担的“参数量 $\times$ 数据量”上限被一个常数因子压缩。15 个情景全部存在可行点，最优选择与成本分解见表 7.2。

（表中 N 的单位为十亿参数， D 的单位为十亿 token。）

三个预算档给出三种性质不同的结果。 10^{22} 档的预算被用尽，利用率在 98.92%–99.64% 之间，说明该档下约束是紧的，选择由预算边界决定；选中点落在 N 与 D 的中段，随上下文长度增加而减少数据量以腾出注意力开销。 10^{19} 档从未用尽预算（78.04%–95.31%），原因是可行网格在该量级上已经稀疏，可用点上界不足以触及预算边界。 10^{24} 档则出现

表 7.2 15 个预算 $\times$ 上下文情景的参考配置与成本分解

预算	L_{ctx}	选中 N	选中 D	预测损失	可行点数	预算利用率
10^{19}	2048	0.162405	8.389	3.030398	39	87.325%
10^{19}	4096	0.162405	8.389	3.030398	36	92.906%
10^{19}	8192	0.162405	6.291	3.087766	34	78.041%
10^{19}	32768	0.162405	4.194	3.176846	27	85.506%
10^{19}	131072	0.070542	4.194	3.392088	16	95.307%
10^{22}	2048	6.861040	226.492	2.145611	1060	99.603%
10^{22}	4096	6.861040	211.812	2.150759	1049	99.100%
10^{22}	8192	6.861040	188.744	2.159845	1032	98.916%
10^{22}	32768	2.782831	285.213	2.194660	969	99.638%
10^{22}	131072	2.782831	111.149	2.271591	793	99.642%
10^{24}	2048	11.965825	299.893	2.093379	1176	2.300%
10^{24}	4096	11.965825	299.893	2.093379	1176	2.447%
10^{24}	8192	11.965825	299.893	2.093379	1176	2.741%
10^{24}	32768	11.965825	299.893	2.093379	1176	4.505%
10^{24}	131072	11.965825	299.893	2.093379	1176	11.560%

明显的支持域受限：1176 个网格点全部可行，最优解一律落在网格上界 $N = 11.965825\text{B}$ 、 $D = 299.893\text{B}$ ，五个上下文的预测损失与训练开销完全相同，利用率仅 2.300%–11.560%，档内差异全部来自注意力开销。

最后一档的结论必须谨慎表述。利用率低并不意味着“预算没有被有效利用”，而是意味着 B1 网格的最大规模已经无法消耗掉这一量级的预算；在网格之外的更大 N 、 D 上损失是否继续下降，本模型没有数据支持回答。因此该档结果只能读作“在 B1 支持范围内， 10^{24} 档的约束不起作用”，不能外推为更大规模的结论。15 个情景的利用率分布见图 7.2。

7.4.3 成本结构只由上下文长度决定

在 $C_Q = 0$ 的设定下，成本份额有一个简洁的解析形式。由 $C_{\text{attn}}/C_{\text{train}} = L_{\text{ctx}}/30000$ 可得




图 7.2 15 个情景的预算利用率与成本份额 ((a) 虚线为预算耗尽线; (b) 虚线为份额过半线)

$$s_{\text{attn}} = \frac{L_{\text{ctx}}/30000}{1 + L_{\text{ctx}}/30000}, \quad s_{\text{train}} = 1 - s_{\text{attn}} \quad (7.8)$$

该式表明份额与预算和选中点都无关，只随上下文长度变化。代入五个可行长度得表 7.3。

表 7.3 成本份额随上下文长度的变化（与预算档位无关）

L_{ctx}	2048	4096	8192	32768	131072
训练开销份额	93.610%	87.987%	78.550%	47.795%	18.625%
注意力开销份额	6.390%	12.013%	21.450%	52.205%	81.375%

这一结构给出一个直接的工程判读：当上下文长度取 32768 时，超过一半的算力预算被注意力开销吃掉；取 131072 时，训练本身只占约 18.6% 的预算。换言之，长上下文的代价不是边际性的，而是会改变预算的主要去向。这正是题目要求考察 L_{ctx} 对最优配置影响的实质。图 ?? 把配置、成本构成与预测损失放在一起对照：面板 (a)(b) 给出各情景选中的 N 与 D ，空心圈标出触及 B1 支持上界的点；面板 (c) 是三类成本的百分百堆叠，直观显示注意力份额如何随上下文长度吞掉训练份额；面板 (d) 为对应的 M0 预测损失。四张面板合读可以看到一件事： 10^{24} 档的五条线全部终止在支持上界，其损失也全部停在同一点，说明该档的差异已不由预算决定，而由可用网格决定。




图 7.3 离散预算与上下文情景下的资源配置、成本构成与 M0 预测损失。(a) 选中的参数量；(b) 选中的数据量；(c) 训练／注意力／质量三类成本的百分百堆叠——固定 $Q = Q_0$ 时质量成本恒为零；(d) M0 预测验证损失。空心圈表示该点触及 B1 的 N 、 D 支持上界，线段仅连接三个给定预算档位。22 对相邻变化仅作描述性比较，不使用 bootstrap 或 KKT 判据，也不构成结构转移结论

7.4.4 成本函数选择的影响

三种 $g(Q)$ 的影响需要分两个层次回答。在固定 $Q = Q_0$ 的主支中， $C_Q \equiv 0$ ，三种形式对最优选择没有任何影响——这一点在结果中直接可见：表 7.2 的每一行都与 g 的选取无关。但这不等于成本函数的选择不重要，而是说明在“不提升质量”的策略下质量成本不进入约束。

在质量提升支中，三种形式的差异显著。把质量由 Q_0 提升到 $Q = 1$ ，在 B1 数据量的中位值 ($D = 146.801\text{B token}$) 处，三种形式所需的增量算力分别为

式中各量的单位均为 FLOPs (g 为每 token 成本，乘以 D 后为总量)。三种形式的增量

表 7.4 质量由 Q_0 提升至 $Q = 1$ 的增量算力 ($D = 146.801 \times 10^9$ token)

成本函数	$g(Q_0)$	$g(1) - g(Q_0)$	增量算力 C_Q
指数型	1.9903×10^8	3.8353×10^9	5.6302×10^{20}
幂函数型	3.0871×10^8	4.6913×10^9	6.8869×10^{20}
对数渐进型	3.5784×10^9	1.2174×10^9	1.7871×10^{20}

算力相差约 3.9 倍，对数渐进型最省、幂函数型最贵。由于增量算力与数据量成正比，其可负担性同时取决于 D 的取值。在 B1 支持上界 ($D = 299.893\text{B}$) 处，把质量提升到 1 所需的算力约为 10^{21} 量级，相当于 10^{22} 档预算的 11.5%、14.1% 与 3.7%，而在 10^{19} 档下远超预算。反过来，若要在 10^{19} 档内完成这一提升，数据量必须压到 2.607B（指数型）、2.132B（幂函数型）或 8.215B（对数渐进型）以下。把该界与表 7.2 的参考配置对照可以看出： 10^{19} 档选中的 D 为 4.194B 至 8.389B，因此指数型与幂函数型在该档的参考配置上完全不可行，对数渐进型只在 8192 及以上三个上下文处可行、在 2048 与 4096 处仍不可行。这说明”成本函数的选择影响最优解”在本问是实质性的：换一种 $g(Q)$ ，最低预算档下质量提升从”完全不可能”变为”部分可行”。质量成本曲线见图 7.3，其中横轴为质量水平、纵轴为对数刻度的增量算力，三条预算参考线标出了各档的可负担边界。




图 7.4 三种质量成本函数的增量算力曲线 (D 取 B1 数据量的最小值、中位值与最大值)

7.4.5 相邻情景的比较与条件性重分配

22 对相邻情景中，17 对的最优配置发生了变化，5 对保持不变——后者包括 10^{19} 档的 2048 到 4096 一步，以及 10^{24} 档因触及网格上界而配置固定的四对。份额转移量 T 在固定上下文的预算对上恒为 0，这与前一小节的解析结论一致：成本份额只依赖 L_{ctx} ，预算变化只改变可行点数量而不改变份额结构。固定预算、改变上下文的对则给出非零的 T ，最大值出现在 8192 到 32768 一步 ($T = 0.3076$)，对应注意力份额从 21.45% 升到 52.21% 的跃变。

条件性质量响应模型的结果如下。45 个情景（3 档预算 $\times$ 5 个上下文长度 $\times$ 3 种成本函数）的下包络共切分为 166 段；其中 15 个情景（全部位于 10^{24} 档）不存在 N 、 D 的重分配，因为在网格上界处任何质量响应都不会改变选择；其余 30 个情景存在有限的重分配阈值，取值落在 0.003241 至 0.624520 之间。阈值较小的情景（如 10^{22} 档配合对数渐进型，阈值约 0.0032）意味着质量响应稍大于零就足以改变最优配置；阈值较大的情景（如 10^{19} 档配合指数型，阈值约 0.6245）则需要相当强的质量响应才会触发重分配。这一谱系本身就是“成本函数选择影响最优解”的定量体现：同一预算下，换个 $g(Q)$ 会使重分配阈值移动一至两个数量级。三个预算档与三种成本函数下的阈值分布见图 7.4。




图 7.5 条件性质量响应模型下首次触发 N 、 D 重分配的质量响应阈值 β_Q （三个面板分别为三种成本函数，横轴为上下文长度，纵轴为对数刻度）。 10^{24} 档的 15 个情景不存在重分配，未绘出

需要重申该支的性质： β_Q 未经数据识别，因此上述阈值不是“实测最优质量”，而是形如“若响应系数达到某值，配置在何处改变”的条件性结论。本文不为 β_Q 编造估计值，也不把它当作问题二的输出。

7.5 模型验证与灵敏度分析

参数不确定性的传播结果是本节的主要验证内容。把问题二保存的 1000 组整轨迹 bootstrap 参数逐一代入，在 15 个情景中重新筛选可行点并重新选择：15 个情景下原选中点均在 1000/1000 次重抽样中被重新选中，选择频率为 1.0，场景内不出现第二个被选中的网格点。预测损失的百分位区间很窄，最宽的一处（ 10^{19} 档配合 2048）也只有 1.3×10^{-4} 。这一结果说明：在既定的 M0 函数形式与 B1 支持网格内，参考配置对参数重抽样是稳定的。

但稳定性的范围必须划清。该检验只覆盖参数不确定性，不覆盖三类误差：M0 的函数形式误设、B1 与目标训练方案之间的迁移误差，以及网格之外的行为。此外， 10^{24} 档的选择受网格上界约束，较窄的 bootstrap 区间不能解除这一边界。因此上述结果支持的是“在当前模型与数据范围内选择稳定”，不支持“该配置就是全局最优”。逐情景的区间与配置切换概率见图 ??：面板 (a)(b) 中 N 与 D 的区间在全部 15 个情景中退化为单点（图中未作放大），面板 (c) 给出预测损失的 2.5%–97.5% 区间，面板 (d) 的配置切换概率在每个情景上都是 0%，即原配置在 1000 次重抽样中从未被替换。面板 (d) 的观感是一条贴在零刻度上的竖线，这本身就是结论——切换从未发生，而不是没有数据。

求解的数值可靠性另有两项证据。其一，全部开销计算使用精确有理数运算而非浮点，可排除 10^{24} 量级上的舍入累积；其二，约束的可行性判定在每个情景中都与独立重算的可行点计数核对一致（表 7.2 的“可行点数”一列）。C7 的输入以 SHA-256 与脚本哈希一并登记，可复算。

质量基线的选择本身也是一项需要检验的设定：问题一给出两个候选，本文取 $Q_{\text{huber}} = 0.498478$ 为主分、 $Q_{\text{eq}} = 0.496223$ 为敏感性对照。把两者分别代入同一套预算、上下文、B1 网格与 M0 后重解，图 ?? 显示两条分支给出的 N 、 D 与预测损失在每个情景上完全重合，逐情景的最大绝对差为 0。该图是一张零结果图，它的价值在于排除一种可能的质疑——即问题三的结论是否依赖问题一那个在两候选间无法用证据区分的操作性选择。答案是：不依赖。需要说明的是，两支都固定在各自基线、 C_Q 均为零，因此这一对照只说明“主分口径不影响预算分配”，**不构成质量收益的实证估计**，也不构成配比与质量的联合优化。

本节必须明确写出尚未执行的部分。按 6.5 设定的结构性转移判据，正式的转移判定需要活动约束集合在 bootstrap 下的改变概率与份额转移量的第 5 百分位，而本文的 bootstrap 只传播了问题二的参数不确定性，且质量成本份额在 $Q = Q_0$ 时恒为零，因此活动约束集合在情景之间不存在统计意义上的可变性。本文据此不作出结构性转移的判定，只报告上文描述性的配置与份额变化。若要完成正式判定，需要先在问题二的配比与质量响应上取得可识别的证据，使 p 或 Q 能够真正进入约束并产生可变的集合。

其余限制一并列出。第一， p 未作为决策变量，本问不回答领域配比的优化问题，理




图 7.6 轨迹级 cluster bootstrap 下的配置选择稳定性。把问题二已有的 1000 次轨迹级 bootstrap 参数传播到 15 个固定 Q 情景：(a) 参数量、(b) 数据量的 95% 区间在全部情景中退化为单点，未作视觉放大；(c) M0 预测损失的 2.5% / 中位数 / 97.5% 分位；(d) 配置切换概率，恒为 0%。该 bootstrap 仅基于 8 条 B1 轨迹，只反映既定 M0 形式与支持网格内的参数重抽样稳定性，不覆盖模型形式误差、外部迁移或配比 / 质量响应

由是问题二的 p 门禁失败。第二， Q 在主支中固定于基线，因此本问给出的是“在现有质量水平下如何分配算力”，而非“应当把质量提升到多少”。第三， N 、 D 只在 B1 的 8×147 实测网格上搜索，不插值不外推， 10^{24} 档的结果因此受网格上界限制。第四，正式的质量—损失响应面仍需问题二提供可识别的独立质量变化证据。




图 7.7 q_{huber} 与 q_{eq} 两个质量基线的固定- Q 敏感性对照。(a) 两个基线数值分别为 0.4984781048 与 0.4962230100；(b)(c)(d) 分别为两个分支下的参数量、数据量与 M0 预测损失，两组曲线在每个情景上完全重合（最大绝对差为 0），故部分序列被另一组遮住。该对照不表示质量对损失的实证收益，也不构成配比与质量的联合优化

7.6 本章小结

本问的交付如下。约束结构方面，三部分开销按题面公式设定，解析给出使注意力开销与训练开销相等的临界上下文长度 $L_{crit}^{crit} = 6/\eta = 30000$ ，并据此确认 C7 的 45 个架构记录中有 12 个 (26.7%) 超过该临界值。参考配置方面，固定质量基线后 $C_Q \equiv 0$ ，15 个预算 $\times$ 上下文情景全部可行； 10^{22} 档预算用尽（利用率 98.92%–99.64%）， 10^{19} 档未触及边界（78.04%–95.31%）， 10^{24} 档的 1176 个网格点全部可行、最优解落在网格上界而利用率仅 2.300%–11.560%。成本结构方面，注意力开销份额只由上下文长度决定，从 2048 处的 6.390% 升至 131072 处的 81.375%。成本函数选择方面，三种 $g(Q)$ 在固定质量的主支中不影响选择；在质量提升支中，把质量由 Q_0 提升到 1 所需算力相差约 3.9 倍（对数渐进型最

省)，且该开销与 D 成正比，故在 10^{19} 档的参考配置上指数型与幂函数型完全不可行、对数渐进型仅部分可行。

本问的结论受三条限制约束。第一，未作结构性转移判定：判据已按可证伪的要求预先定义，但正式判定所需的活动约束可变性依赖问题二尚未识别的配比与质量响应，故本章只报告描述性的份额与配置变化。第二， p 未作为决策变量， Q 在主支中固定于基线，因此本问回答的是给定质量水平下的算力分配，不是 N 、 D 、 p 、 Q 的联合最优。第三，候选点限于 B1 实测网格， 10^{24} 档的结果受网格上界限制，不能外推为更大规模的结论。

本问交付给问题四的是算力约束下的配置关系与成本结构：问题四在把损失翻译为能力得分时，可以据此说明算力增长放缓情景下的配置含义。

8 问题四的模型建立与求解

8.1 问题四分析

8.2 模型建立

8.3 模型求解

8.4 结果分析

8.5 模型验证与灵敏度分析

8.6 本章小结

9 模型稳健性与综合检验

9.1 参数灵敏度与随机性

9.2 消融实验

9.3 误差分解与失效案例

9.4 外推与分布偏移

10 模型的评价、改进与推广

10.1 模型的优点

10.2 模型的缺点

10.3 模型的改进方向

10.4 模型的推广

附录 A 问题一主要程序

problem1.py

```
# 【粘贴问题一的核心代码。附录代码要点：  
# 1. 只放关键部分，不是把整个工程贴上来  
# 2. 必须有注释说明每一步在做什么  
# 3. 结果要能被正文的数字复现  
# 4. 函数名尽量与正文模型名对应，方便评委核对】
```

附录 B 问题二主要程序

problem2.py

附录 C 问题三主要程序

problem3.py

附录 D 问题四主要程序

problem4.py

附录 E 人工智能使用披露

按照第二十三届中国研究生数学建模竞赛 F 题《五、AI 使用规范》的要求，本文如实披露参赛过程中人工智能工具的使用情况。

E.1 使用的 AI 工具

工具名称	版本	提供方	使用时段
【例：Claude Code】	【例：Fable 5】	【例：Anthropic】	【例：09-23 至 09-26】
【工具二】	【版本号】	【提供方】	【时段】

表 E.1 参赛过程中使用的人工智能工具

E.2 使用环节与贡献范围

使用环节	AI 的具体贡献	参赛队的独立工作与核验
概念理解	【例：协助梳理【某方法】的基本原理与适用条件】	【例：查阅【文献】核实其推导；确认适用条件在本题数据上成立】
资料整理	【例：协助检索【某领域】的公开文献线索】	【例：逐篇核对原文与出处，正文引用均以正式发表文献为准】
代码调试	【例：协助排查【某函数】的报错与数值稳定性问题】	【例：自行完成算法设计与实现；对 AI 建议逐条测试，用【某验证】确认结果正确】
【其他环节】	【具体贡献】	【独立工作】

表 E.2 AI 工具的使用环节与贡献范围

E.3 对 AI 输出的核验与处理

针对人工智能工具给出的每项输出，参赛队均按以下流程处理：

1. 来源核验：凡涉及理论、公式与实验结论的内容，均回溯至正式发表的文献或可核验的公开数据，不以人工智能工具的输出作为学术依据；正文所有引用均指向正式文献（见参考文献）。

2. **独立复算**：凡涉及数值结果的内容，均由参赛队自行编写的程序（见附录 A–D）独立复算，论文报告的每个数值均可追溯至 `state/` 数字登记表.csv 登记的结果。
3. **处理说明**：【填写具体例子——例如“AI 曾建议采用某方法，经验证在本数据上不满足某前提，故改用另一方法”，或“AI 给出的某公式存在某错误，经推导修正为……”。真实的修正例子比空泛声明更有说服力。】

E.4 由参赛队独立完成的工作

本文的核心建模、数学推导、算法设计、参数选取、实验方案与结论论证，均由参赛队独立完成。具体包括：

- 问题的数学抽象与建模思路的提出；
- 全部数学模型的建立与公式推导；
- 求解算法的设计、实现与调参；
- 实验方案设计、结果计算与灵敏度分析；
- 数据预处理规则与评价指标的确定；
- 论文的撰写与图表制作。

人工智能工具在本参赛过程中的作用限于辅助性质的概念理解、资料检索与代码调试，未参与上述核心建模与推导工作。