



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

新疆大学、山西大学

参赛队号

26107550075

队员姓名

1. 赵梦辰

2. 杨博尧

3. 张万杰

题 目: 【论文题目】

针对问题一，
针对问题二，
针对问题三，
针对问题四，

1

目录

1	问题重述	5
1.1	问题背景	5
1.2	问题的提出	5
2	问题分析	6
2.1	总体技术路线	6
2.2	问题一分析	6
2.3	问题二分析	6
2.4	问题三分析	6
2.5	问题四分析	6
3	模型假设与符号说明	6
3.1	模型假设	6
3.2	符号说明	7
4	数据描述与预处理	8
4.1	数据来源与说明	8
4.2	数据探索与可视化	8
4.3	数据清洗与特征构建	8
5	问题一的模型建立与求解	9
5.1	问题一分析	9
5.2	模型建立	9
5.2.1	公共预处理与指标方向统一	9
5.2.2	质量评分模型	10
5.2.3	冲突度定义与消解规则	12
5.2.4	领域配比与损失的定量关系模型	13
5.3	模型求解	14
5.4	结果分析	16
5.4.1	质量评分结果	16
5.4.2	冲突分析与消解结果	17

5.4.3	配比—损失模型结果	19
5.5	模型验证与灵敏度分析	24
5.6	本章小结	26
6	问题二的模型建立与求解	28
6.1	问题二分析	28
6.2	模型建立	28
6.3	模型求解	28
6.4	结果分析	28
6.5	模型验证与灵敏度分析	28
6.6	本章小结	28
7	问题三的模型建立与求解	29
7.1	问题三分析	29
7.2	模型建立	29
7.3	模型求解	29
7.4	结果分析	29
7.5	模型验证与灵敏度分析	29
7.6	本章小结	29
8	问题四的模型建立与求解	30
8.1	问题四分析	30
8.2	模型建立	30
8.3	模型求解	30
8.4	结果分析	30
8.5	模型验证与灵敏度分析	30
8.6	本章小结	30
9	模型稳健性与综合检验	31
9.1	参数灵敏度与随机性	31
9.2	消融实验	31
9.3	误差分解与失效案例	31
9.4	外推与分布偏移	31

10 模型的评价、改进与推广	32
10.1 模型的优点	32
10.2 模型的缺点	32
10.3 模型的改进方向	32
10.4 模型的推广	32
参考文献	32
附录 A 问题一主要程序	33
附录 B 问题二主要程序	34
附录 C 问题三主要程序	35
附录 D 问题四主要程序	36
附录 E 人工智能使用披露	37
E.1 使用的 AI 工具	37
E.2 使用环节与贡献范围	37
E.3 对 AI 输出的核验与处理	37
E.4 由参赛队独立完成的工作	38

1 问题重述

1.1 问题背景

大语言模型的能力提升主要依赖三条途径：扩大参数规模、增加训练数据量、延长上下文长度。三者均需付出算力代价，且代价结构各异。参数量翻倍时，训练开销近似同倍增长；按经典估计，数据量应与参数量同比例增长，二者的乘积决定了基础训练开销的量级；上下文长度的代价增长更为迅速——从数千 token 扩展至数十万，注意力的计算量与 KV 缓存的显存占用同步上升，将迅速挤占本可分配给参数与数据的算力预算。然而，规模扩张并不必然带来能力提升。2026 年 2 月《Nature》刊载的一项研究提供了反例：参数量仅 80 亿的 OpenScholar-8B，在引文准确率与降低幻觉两项任务上超过了 GPT-4o。

该研究将差距归因于数据因素，即数据质量与领域配比，而非参数规模。这反映了当前大模型训练面临的现实约束：模型对高质量语料的需求持续增长，而满足要求的干净语料日益稀缺，数据污染日趋严重，即所谓“数据墙”问题。领域配比的作用尤为特殊：调整各领域数据的混合比例并不增加总算力开销，却改变算力在领域间的分配效果，进而影响最终的损失 [1]。

现有定量方法尚不足以回答“算力应投向何处”。广泛采用的标度律将交叉熵损失表示为参数量与数据量的幂函数之和，形式简洁、便于外推，但仅含参数量 N 与数据量 D 两个自变量，未显式纳入数据质量 Q 与领域配比 π [2, 3]。换言之，上述两个被实践反复证明重要的因素，在该框架中只能以常数或噪声的形式出现。一旦将 Q 与 π 视为可调决策变量，经典形式即不再适用。另一方面，上下文长度通过长文本注意力开销压缩可用预算，该项亦未被经典标度律涵盖，其对最优配置的影响需单独解析，无法通过回归现有数据获得。因此，研究算力受限条件下的资源配置，须先将数据质量与领域配比纳入标度律，再在算力预算约束下，对参数量、数据量、领域配比与数据质量进行联合优化。

1.2 问题的提出

根据题目提供的三类附件数据，本文需完成以下四项工作。

问题一：数据质量评价、冲突消解与领域配比建模

题目所给质量信号数据覆盖 22 个评价维度，各维度方向不一致，教育价值越高越好而广告含量越低越好，建模前须将全部指标统一为“越高越好”。本文首先在抽样集 A1 上建立分位校准，把 22 个指标映射到同一无量纲尺度，并对中心型指标改用指数核处理；进而在该尺度上构造等权与稳定性加权 Huber 两个并列的质量评分候选，同时以样本内平均两两绝对分差定义指标冲突度、以各来源域的第 95 百分位为高冲突阈值，并报告两候选之差作为消解结果；最后利用 512 条配方建立带单纯形约束的多输出收缩回归，刻画 17 域配比与 13 个损失目标之间的定量关系。模型在同尺度检验集 A6/A7 上取得 $R^2 = 0.619$ 、Spearman = 0.833，跨尺度检验集 A8–A11 的 R^2 转负而秩相关仍保持 0.73–0.83，据此将结

论限定为同尺度内的配比筛选；外推表 A12–A15 用于估计表的一致性比对。

问题二：跨维度数据融合与广义标度律

本问要求将数据质量 Q 与领域配比 π 纳入标度律。附件 B 提供不同模型族、不同规模下的训练日志与损失记录，其中一部分为基于真实数据校准的半合成补充数据。本文以【方法】构造同时含参数量、数据量、数据质量与领域配比的广义标度律，以【方法】完成参数估计，据此计算各因素的边际效用与弹性，并推导质量提升与规模扩大可相互替代的条件。

问题三：算力约束下的多维资源联合优化与结构性转移

本问在总算力预算受限的条件下完成资源分配。算力预算由三部分消耗：基础训练开销随参数量与数据量的乘积增长；数据质量由基线提升至目标水平需要额外算力，其规模取决于成本函数的形式；长文本注意力开销随上下文长度上升，且增速快于线性。上下文长度由题目外生给定，不作为寻优变量，但通过第三项开销影响前两项的可用预算，故仍须纳入模型。本文以【方法】建立约束优化模型，在低、中、高三档预算下求解最优的参数量、数据量、配比与质量组合，解析给出使注意力开销与训练开销相当的临界上下文长度，并给出结构性转移的数学定义与识别方法。

问题四：技术演进分析与前沿能力预测

本问处理技术演进的定量分析。附件 C 提供开源模型的能力评测结果、算力与数据量元数据，以及损失与测评得分之间的桥接数据。本文以【方法】将模型能力增长分解为规模扩张与非规模技术进步两部分，分别量化二者的贡献占比，再以【方法】预测未来 12 个月与 24 个月的开源模型能力前沿，并给出不确定性区间。

2 问题分析

2.1 总体技术路线

2.2 问题一分析

2.3 问题二分析

2.4 问题三分析

2.5 问题四分析

3 模型假设与符号说明

3.1 模型假设

1. 【假设一：依据……，将……近似为……；该处理可能在……处产生……偏差，后文通过……（图/表编号）检查。】




图 2.1 本文总体技术路线图

2. 【假设二】

3. 【假设三】

3.2 符号说明

表 3.1 符号说明表

符号	含义	单位
i, j	索引（如节点、架次、样本）	—
N	规模参数（写明具体取值，如“取 $N=122$ ”）	—
x_{ij}	决策变量：……	—
θ	模型参数：……	【单位】
$\mathcal{L}$	目标函数：……	—

（提示：选题后删除本行，按需增删符号行）

4 数据描述与预处理

4.1 数据来源与说明

4.2 数据探索与可视化

4.3 数据清洗与特征构建

5 问题一的模型建立与求解

5.1 问题一分析

题目给出的数据分为两类。质量信号数据 A1–A3 覆盖 22 个评价维度，用于质量评价与冲突分析，其中 A1 是七个来源域的抽样集，A2 与 A3 分别为 arxiv 与 github 两个域的扩展集；配方实验数据 A4–A15 记录 17 个训练领域在不同混合比例下的交叉熵损失，A6–A11 为检验集，A12–A15 为外推表。两类数据采用不同的域分类体系，须借助 A16 的映射指南建立跨体系关联。本问需交付三项结果：方向统一后的质量评分 Q 、冲突的定义与消解规则，以及 17 域配比 π 与损失之间的定量关系模型。

建模的困难主要来自数据本身。22 个指标的方向与量纲均不一致，教育价值越高越好而广告含量越低越好，dsir 系列的中位数处于 -2100 量级而 rps 系列的比例型字段又在百分量级，直接加权没有意义。配比数据的结构同样特殊：17 个配比域中只有 13 个具备对应的验证损失，且训练集 512 条配方中有 511 条含零配比，逐分量的对数比变换会因零值而失效。配比表的行和只在三位小数的意义上等于 1，实测范围为 0.996–1.003，单纯形约束在数据中只是近似成立。三个数据集的规模差异亦不容忽视，A3 有 203752 条记录，为 A1 的 3.98 倍、A2 的 11.63 倍，若逐集重新拟合归一化参数，跨集比较将失去共同基准。

本问输出的 Q 与 π 是问题二的输入，问题二须在标度律中引入这两个量，因此本问必须给出 Q 的可比尺度与 π 的完整定义。

5.2 模型建立

5.2.1 公共预处理与指标方向统一

质量信号共 272505 条记录，分布为 A1 抽样集 51230 条、A2 扩展集 17523 条与 A3 扩展集 203752 条，预处理后的数据全貌见表 5.1。三集的行数在预处理前后完全一致，缺失率最高为 $18/51230 = 0.035\%$ 。异常标记按稳健标准化残差判定，阈值取 $|z| > 3.5$ ，其中

$$z_j(x) = \frac{x - m_j}{s_j}, \quad s_j = \begin{cases} 1.4826 \text{ MAD}_j, & \text{MAD}_j > 0 \\ \text{IQR}_j/1.349, & \text{MAD}_j = 0, \text{IQR}_j > 0 \\ \sigma_j, & \text{否则} \end{cases} \quad (5.1)$$

式中， m_j 为第 j 个指标的稳健中心， s_j 为其稳健尺度，优先取 1.4826 倍中位绝对偏差，当该量退化时依次回退到四分位距与标准差。该标记只用于标注而不作为删除依据，三集行数在预处理前后保持不变即是这条规则的直接结果。

方向统一在 A1 上一次性完成，A2/A3 只套用参数而不重新拟合。对第 j 个指标，记 $F_{j,A1}$ 为其在 A1 上拟合的分位函数，则

$$u_j(x) = \begin{cases} F_{j,A1}(g_j(x)), & \text{正向指标} \\ 1 - F_{j,A1}(g_j(x)), & \text{负向指标} \\ \exp\left(-\frac{|g_j(x) - m_j|}{s_j}\right), & \text{中心型指标} \end{cases} \quad (5.2)$$

式中, g_j 为指标的原始变换 (词数、句数两个字段先取 $\log(1+x)$), $u_j \in [0, 1]$ 为方向统一后的无量纲得分, 对任何指标, 取值越接近 1 表示该维度上的质量越好。三类方向中, 中心型指标的含义略有不同: 偏离中位过远 (无论偏高还是偏低) 都会被扣分, 故采用指数核而非单调映射。分位函数在 2001 个分位点上取值, 两端按 $[0.005, 0.995]$ 截尾, 截尾避免极值把尺度拉长, 代价是极端样本被压缩到端点。列表型字段先压缩为标量再参与上述流程, 规则见表 5.2。

表 5.1 A1–A3 的样本规模、缺失与异常标记

数据集	原始行	处理后行	缺失值	非法值	单位疑似	异常标记
A1	51230	51230	18	0	4	63708
A2	17523	17523	0	0	0	75785
A3	203752	203752	1	0	16	385678

表 5.2 列表型指标到标量的压缩规则

字段	列表长度	压缩方式	理由
fineweb_edu	1	取唯一元素	本身即单值
ad_en、fluency_en	2	softmax 后取第 2 类	第 2 类为正向事件
modernbert_*	6	期望等级 $\div 5$	有序等级, 取期望保序
qurater	4	算术平均	四个子维度等权

22 个指标中有 7 个 `rps_*frac*` 字段的原始取值范围越界或单位来源无法核实, A1 命中 4 行、A3 命中 16 行, 这些字段未做替换或截断而原样进入模型, 其影响在 5.5 中单独报告。22 个指标经方向统一后的分布见图 5.1。

5.2.2 质量评分模型

质量评分给出两个并列候选, 二者的差别只在样本内的聚合方式。等权候选取 22 个 u_j 的算术平均,




图 5.1 22 个质量指标经方向统一后的分布（红色标签为 7 个单位来源未核实的字段）

$$Q_{eq}(x) = \frac{1}{J} \sum_{j=1}^J u_j(x), \quad J = 22 \quad (5.3)$$

稳定性加权候选则以 Huber 位置估计替代算术平均，其权重由指标完整度与排序稳定性两部分相乘得到：

$$w_j = \frac{r_j}{\sum_k r_k}, \quad r_j = (c_j \cdot S_j)^\alpha \quad (5.4)$$

式中， c_j 为该指标在 A1 上的完整度（非缺失记录占比）， S_j 为域排序稳定性——将 A1 七个来源域各自的中位数排序重复抽样 1000 次，取该指标秩相关的中位数； α 为权重指数，主口径取 $\alpha = 1$ 。代入后 18 个指标的权重为 0.045492，其余 4 个因完整度或稳定性略低而略小：modernbert_reasoning 与 modernbert_professionalism 的完整度分别为 0.9997 与 0.9999，权重降至 0.045486 与 0.045490；qurater 与 rps_lines_numerical_chars_fraction 的排序稳定性为 0.9821，权重取最小值 0.0450840。权重指数取 $\alpha = 0.5$ 与取 $\alpha = 1$ 在本数据上给出完全相同的样本分，最大绝对差为 0、秩相关为 1，原因在于各指标的 r_j 本身接近，幂次不足以进一步区分，故不需在 α 上继续搜索。

Huber 位置的阈值取 $\delta = 1.345 s_0$ ，其中 $s_0 = 1.4826 \text{ MAD} = 0.29484$ ，得 $\delta = 0.39655$ 。

系数 1.345 是标准正态下 95% 效率对应的常数，其含义是残差在 δ 以内按平方损失处理，超出后转为线性，从而把单个指标极端取值的影响限制在有界范围。样本分向域级聚合按域内 Huber 位置计算，并给出 $B_Q = 2000$ 次记录级 bootstrap 的百分位 95% 区间。权重校准的过程见图 5.2，完整的评分流程见图 5.3。




图 5.2 指标权重的两个构成分量：完整度与排序稳定性

5.2.3 冲突度定义与消解规则


当不同质量指标对同一文本给出不一致评价时，需要定义冲突、分析成因并给出消解规则。本文把冲突定义为指标之间的分歧幅度，用行内平均两两绝对分差度量：

$$D(x) = \frac{2}{J(J-1)} \sum_{1 \leq j < k \leq J} |u_j(x) - u_k(x)|, \quad \binom{22}{2} = 231 \quad (5.5)$$

式中， $u_j(x)$ 为样本 x 在第 j 个维度上方向统一后的得分。 D 只衡量指标之间是否互相矛盾，不判定哪一项指标有误——在缺少外部真值的条件下，无从判断 **dsir_math** 与 **rps_doc_unigram_entropy** 二者孰是孰非。高冲突阈值取 A1 各来源域内 D 的第 95 百分位 (NumPy method=linear 插值)，A2/A3 一律套用同名域的 A1 阈值以保证跨集可比；消解规则采用稳定性加权 Huber 位置，并报告两候选之差 $\Delta Q = Q_{\text{huber}} - Q_{\text{eq}}$ 。

上述阈值属于描述性的上尾截断而非假设检验：以 q_{95} 作阈值意味着高冲突样本恒占 5%，这是定义使然，不能读作“5% 的样本确实存在冲突”。冲突度与阈值的联合作用在于

F 题 Q1.1 建模与验证数据流



范围限定为 Q1.1; Q1.2、Q1.3 与题目分析报告保持独立。

图 5.3 质量评分的建模流程

给出排序，而非作出绝对判定。冲突诊断与消解的完整流程见图 5.4。


5.2.4 领域配比与损失的定量关系模型

配比建模只使用 A4/A5 的 512 条训练配方，其配比矩阵 $P \in \mathbb{R}^{512 \times 17}$ 的每一行满足单纯形约束，待预测的损失矩阵 $Y \in \mathbb{R}^{512 \times 13}$ 含 13 个目标。配比域比损失目标多 4 个，这 4 个域的损失无从观测，只能在回归中作为不可观测分量处理，这是模型的结构性限制。配比先做闭合归一化 $p_{rj} = x_{rj} / \sum_k x_{rk}$ ，同时保留原始版本用于对照；闭合的必要性在于行和并非精确为 1，实测范围为 0.996–1.003。闭合同时改变了零单元的语义，原始零配比在闭合后仍是零，但非零分量会被等比放大，故 512 条配方的最近邻 L_1 距离由 0 变为 0.0220。

主模型为带单纯形约束的多输出收缩回归。记参考域为 j_0 ，模型写成

$$\hat{y}_{ri} = a_i + \sum_{j \neq j_0} \beta_{ij} p_{rj}, \quad \text{s.t.} \quad \sum_{j=1}^{17} \beta_{ij} = 0, \quad i = 1, \dots, 13 \quad (5.6)$$

Q1.2 冲突分析与污染敏感性流程



主分支只读冻结 norm_*；污染支流仅重估 A1 校准并比较稳定性。A2/A3 无原文字段，外部复核限于冻结评分表条件下。

图 5.4 冲突诊断与消解的建模流程

式中， a_i 为第 i 个损失目标的截距， β_{ij} 为第 j 个域的配比系数，约束 $\sum_j \beta_{ij} = 0$ 消去”全部域同比例增加”这一不可辨识方向——配比之和恒为 1，系数只有满足该约束才唯一。参考域取 `uspto_backgrounds`，其系数固定为 0，收缩强度由岭参数 λ 控制，主口径取 $\lambda = 10^{-4}$ ，由 A4/A5 内部的分组交叉验证网格选出。

质量评分 Q 是否进入配比模型由参赛队伍自行论证。本文不引入 Q ，理由是识别性：若把 Q 作为与配比并列的回归项，模型形如 $p^T b + \theta Q$ ，而 Q 的域级取值本身就是各域配比的函数，两者在 $p^T(b + \theta \tilde{Q})$ 的意义下不可分别识别，在缺少外部真值的前提下强行加入只会使系数失去解释。因此本文改用配比单独建模，把 Q 留给问题二的标度律处理。

除主模型外，另设四个对照与敏感性变体，即训练均值空模型（下界）、参考分量 OLS（截距加 16 个分量、参考系数固定为 0）、Huber 岭回归（ $\rho_{1.345}$ ，用于检验异常损失的影响）与零友好的二次面（17 个一次项与 136 个两两乘积项，共 153 项）。二次面仅作敏感性对照，153 个系数由 512 条配方估计，过拟合风险明显，故不参与模型族选择。选模过程完全在 A4/A5 的分组交叉验证内完成，A6–A11 只用于评估冻结后的模型，A12–A15 只用于与估计表比对一致性，不参与任何调参。配比与各损失目标之间的相关系数见图 5.5。

5.3 模型求解

求解流程分四步，依次是归一化校准、权重构造、配比回归与不确定性估计。权重中的域排序稳定性通过重复抽样估计，Huber 位置用迭代重加权最小二乘求解，配比回归的




图 5.5 配比与损失目标之间的相关系数结构（红色标签为 4 个无对应验证损失的配比域）

岭参数在网格上按分组交叉验证误差选取，替代效应则用配对 **bootstrap** 给出区间，配比回归部分的伪代码见表 5.3。

表 5.3 带单纯形约束的多输出回归求解步骤

步骤	操作
1	读入配比矩阵 P 与损失矩阵 Y ，按行闭合 $p_{rj} \leftarrow x_{rj} / \sum_k x_{rk}$
2	按来源分组（ index ）划分 K 折，保证同组不跨折
3	for 每个候选 λ do 在 K 折上计算标准化 MSE
4	选 $\hat{\lambda} = \arg \min_{\lambda} CV(\lambda)$ ，重拟合得 $\hat{B}, \hat{a}$
5	if 用 Huber 变体 then IRLS 迭代至权重收敛（最大 13 轮）
6	用 $\hat{B}, \hat{a}$ 预测 A6–A11，按目标汇总 MAE/RMSE/ R^2 /Spearman
7	对每个域对做 500 次配对 bootstrap ，得 10 个百分点替代效应的 95% 区间

求解的可靠性可由三项收敛证据支持：Huber 变体在 13 个损失目标上全部收敛，最大

迭代 13 轮；各目标被降权的训练配方数最多为 24 条（arxiv 与 github），权重低于 0.5 的仅 1 条；参考分量 OLS 的设计矩阵条件数在五折内为 [198.7, 209.4, 235.0, 204.9, 206.6]，远低于 10^7 的病态告警阈值。

5.4 结果分析

5.4.1 质量评分结果

A1 七域的域级质量评分见表 5.4，两候选的宏平均分别为 0.49622（等权，95% 区间 [0.49491, 0.49763]）与 0.49848（Huber，[0.49657, 0.50043]）。两候选给出的排名基本一致，分歧集中在 book 与 github 两个域：等权分把 book 排在 github 之前（0.43160 对 0.40450），Huber 分则把两者拉近（0.42875 对 0.38948），差异的来源可从 5.5 的冲突分析中找到——book 正是指标分歧最大的域。各域评分及其区间见图 5.6。

表 5.4 各来源域的域级质量评分（等权与加权两候选）

数据集	来源域	记录数	Q_{eq}	Q_{huber}
A1	arxiv	1419	0.53210	0.56133
A1	book	171	0.43160	0.42875
A1	c4	10000	0.57053	0.57673
A1	commoncrawl	9640	0.53401	0.53597
A1	github	10000	0.40450	0.38948
A1	stackexchange	10000	0.51734	0.51837
A1	wikipedia	10000	0.48349	0.47871
A2	arxiv	17523	0.53096	0.55997
A3	github	203752	0.40394	0.38887

同域迁移检验的结果见表 5.5。A2 与 A3 分别是 A1 中 arxiv 与 github 两个域的扩展集，由于归一化参数只在 A1 上拟合，同域扩展集相对抽样集的评分偏移即反映标量层面的可比性。四个差值的 95% 区间全部跨零，点估计均在千分位以下，说明在 A1 上拟合的参数直接套用到两个扩展集时，域级评分没有可检出的偏移。差值及其区间另见图 5.7。这一比较限定在标量层面，A2/A3 的特征文件不含原文内容，原文层面的效度验证需借助 A18 的原始文本样例另行完成。




图 5.6 各来源域的域级质量评分及估计区间

表 5.5 同域扩展集相对抽样集的评分偏移（bootstrap 区间）

对比	候选	差值	95% 区间
A2 arxiv – A1 arxiv	Q_{eq}	−0.00114	[−0.00288, 0.00070]
A2 arxiv – A1 arxiv	Q_{huber}	−0.00136	[−0.00399, 0.00128]
A3 github – A1 github	Q_{eq}	−0.00056	[−0.00185, 0.00086]
A3 github – A1 github	Q_{huber}	−0.00061	[−0.00211, 0.00085]

5.4.2 冲突分析与消解结果

各域的中位冲突度与 q_{95} 阈值见表 5.6。arxiv 的中位冲突度最高(0.4382), stackexchange 最低 (0.2712)，两者相差 0.167；扩展集的冲突度与同域 A1 高度接近，A2 为 0.4393、A3 为 0.3236。表中 A1 各域的高冲突率恒为 0.0500，这是 q_{95} 阈值的定义使然；A2 的 0.0447 与 A3 的 0.0514 则说明扩展集在套用 A1 阈值后，落入高冲突区的比例与原集基本一致。各域的冲突度分布与阈值见图 5.8。

指标对层面的分歧结构更为具体。A1 七域宏平均下冲突最激烈的三对依次是 dsir_math 与 rps_doc_unigram_entropy (0.5993)、dsir_wiki 与同一元熵指标 (0.5963)、dsir_books 与同一元熵指标 (0.5953)，三对均含 rps_doc_unigram_entropy，其成因可以




图 5.7 同域扩展集与 A1 的域分差值

表 5.6 各来源域的冲突度水平与高冲突判定阈值

数据集	来源域	中位冲突度	q_{95} 阈值	高冲突率
A1	arxiv	0.4382	0.4660	0.0500
A1	book	0.4098	0.4476	0.0526
A1	c4	0.3241	0.4188	0.0500
A1	commoncrawl	0.2883	0.3834	0.0500
A1	github	0.3232	0.4294	0.0500
A1	stackexchange	0.2712	0.3598	0.0500
A1	wikipedia	0.3069	0.4079	0.0500
A2	arxiv	0.4393	0.4660	0.0447
A3	github	0.3236	0.4294	0.0514

解释：**dsir** 系列衡量文本与某一参考语料的相似度，而一元熵衡量文本自身词汇分布的分散度，后者高的文本未必与任何参考语料接近，两者的评价对象并不相同。231 个指标对的分歧结构见图 5.9。

消解后的评分为 Q_{huber} 。在高冲突组内，两候选的差值方向并不统一，**github** (-0.0497)、**wikipedia** (-0.0330) 与 **c4** (-0.0056) 为负，而 **arxiv** ($+0.0438$)、**book** ($+0.0393$) 与 **commoncrawl** ($+0.0127$) 为正。**book** 域的分歧幅度尤为突出，其高冲突组的 $|\Delta Q|$ 中位数为 0.0393，是其余组 0.01973 的两倍，与表 5.6 中 **book** 唯一非 0.05 的高冲突率互为印证。扩展集上的外部复核结果见图 5.10。




图 5.8 各来源域的域内冲突度分布（红色虚线为该域的 q_{95} 高冲突阈值，灰色竖线为中位数）

冲突度与评分分歧幅度的关系见图 5.11。

5.4.3 配比—损失模型结果

模型选择的结果见表 5.7。三个主要候选的差别不大但有稳定顺序，单纯形岭回归的分组交叉验证标准化 MSE 为 0.39860，略优于参考分量 OLS 的 0.40032，两者都远优于训练均值空模型的 1.00448。模型族的交叉验证对比见图 5.13。主模型相对基线的逐目标改善见图 5.12。

主模型在 A4/A5 上的嵌套交叉验证给出宏平均 $R^2 = 0.59923$ 、Spearman $\rho = 0.82077$ 、MAE = 0.41972、RMSE = 0.49780，五折的外层选模全部选中同一个模型族，选模流程本身稳定。冻结检验集与估计表上的表现见表 5.8。

同尺度的 A6/A7 上模型表现可用， R^2 为 +0.619；跨到 60M 与 1B 后 R^2 急剧转负，但同期 Spearman 仍保持在 0.73–0.83。二者的差异指向不同的失效机制： R^2 的负值来自尺度失配——随训练尺度增大，各域验证损失的整体水平下降，而主模型的系数在 1M 尺度上




图 5.9 质量指标两两冲突强度的分布（琥珀色为 dsir 系列与一元熵的组合）




图 5.10 冲突指标在扩展集上的复核结果

估计、不含任何尺度项，无法跟随均值漂移；Spearman 则说明模型的排序能力仍然保留。据此，该模型的适用范围限定为同一训练尺度内的配比筛选，不能作为跨尺度的定量外推工具。同尺度留出集上的观测值与预测值对照见图 5.14，跨尺度 RMSE 见图 5.15。

替代效应的方向结构见表 5.9。136 个域对中有 106 对在训练集上有足够份额支持 10 个百分点的替代，其 1378 个目标与域对组合的区间中，214 个全为正、535 个全为负、629 个跨零。区间跨零占近一半，说明多数替代方向在本数据上尚无定论。这些区间条件于已选模型族、已选 λ 与观测训练分布，逐点计算且未做多重比较校正，系数只反映关联而非




图 5.11 冲突度与评分分歧幅度的关系




图 5.12 主模型相对训练均值基线的拟合误差改善

表 5.7 三种配比模型族的分组交叉验证误差

模型	标准化 MSE↓	正则强度 λ	角色
单纯形岭回归（主模型）	0.39860	10^{-4}	选中
参考分量 OLS	0.40032	—	对照
Huber 岭回归	0.40165	3.16×10^{-5}	稳健性敏感性
二次面（153 项）	0.34238	0.2848	非线性敏感性
训练均值空模型	1.00448	—	下界




图 5.13 三种配比模型族的分组交叉验证误差

表 5.8 各检验尺度上的预测误差与秩相关（13 个目标宏平均）

数据	尺度关系	MAE↓	RMSE↓	$R^2 \uparrow$	Spearman↑
A6/A7（1M）	同尺度	0.3876	0.4539	+0.6189	0.8327
A8/A9（60M）	跨尺度	1.5125	1.5590	-7.9336	0.8314
A10/A11（1B）	跨尺度	3.1830	3.1970	-810.12	0.7268
A12/A13（10B）	外推估计表	3.5730	3.6016	-236.86	0.4896
A14/A15（70B）	外推估计表	3.9556	3.9848	-385.31	0.4132




图 5.14 同尺度留出集上预测损失与观测损失的一致性




图 5.15 检验尺度对预测误差与秩相关的影响：误差随尺度恶化而秩相关保持

因果效应，故区间本身不作为显著性结论。替代关联系数见图 5.16。

各组合的方向确定性见图 5.17。

各检验集上误差最大的目标一并列出：A6/A7 上为 `the_pile_dm_mathematics_val_loss` (RMSE 1.1634)，A8/A9 与 A10/A11 上均为 `github` (2.6333 与 4.4280)，A12/A13 与 A14/A15 上均为 `ubuntu_irc` (4.4513 与 4.9323)。最大的预测五分位偏差出现在 `dm_mathematics` 的第 5 组，预测减观测为 -0.5174 ，即高损失区存在系统性低估。

表 5.9 配比替代效应区间估计的方向构成

类别	数量	占比
受支持的域对	106	77.9%（占 136 对）
区间全为正	214	15.5%
区间全为负	535	38.8%
区间跨零	629	45.7%
不受支持的域对	30	22.1%（占 136 对）




图 5.16 配比替代效应的关联系数结构（系数满足 $\sum_j \beta_{ij} = 0$ ，参考域固定为 0）

5.5 模型验证与灵敏度分析

本节的验证围绕一个目标：考察前述结论对预处理参数、权重构造与数据中异常记录的稳定性，主要场景见表 5.10。

影响最剧烈的是剔除 7 个单位存疑字段，A1 样本分的 P95 绝对差达 0.113048、最大差 0.255681，A2 上的秩相关降到 0.729556，说明评分对这批字段的依赖是实质性的，故本




图 5.17 配比替代效应的方向确定性 (1768 个目标与域对组合中 895 个方向稳定)

表 5.10 评分对字段与权重设定的敏感性

敏感性场景	样本分 P95 绝对差↓	排序 Spearman↑	判读
剔除 7 个单位存疑字段	0.113048	0.872404	影响最大，排序仍稳
Huber 阈值 $\delta \times 0.5$	—	0.980320	影响有限
权重指数 $\alpha = 0.5$	0	1.000000	完全等价
剔除单位存疑的 A1 行	10^{-6}	1.000000	可忽略

文只将 Q 称为受限候选分，而不称其为 22 路信号的完整综合。相比之下，Huber 阈值折半只带来 0.007374 的宏平均位移（秩相关 0.980），权重指数 α 的选择则完全不影响结果。

污染敏感性另作一项检验。对 A1 的原文做逐记录的 Unicode 完整性审计，按窄口径（格式字符与除制表、换行外的控制字符）检出 428 条，按宽口径（并含私用区与非法码点）检出 463 条，分别占 51230 条的 0.836% 与 0.904%。题目材料的历史报告中曾出现 334 条这一计数，但现有扫描规则无法复现，故不作为本次结果引用。两套规则各自对应一组敏感性结果，将相应记录分别从阈值、权重、Huber 阈值与指标对排序的估计中剔除后：权

重向量的 L_1 变化为 0.001002 (窄) 与 0.000788 (宽); 权重排序的 Spearman 为 0.5274 (窄) 与 0.6550 (宽); Huber 阈值由 0.396554 变为 0.396452 (窄) 与 0.396442 (宽); 各域高冲突阈值的最大位移出现在 book 域 (-0.001438), 其余域在 $\pm 3 \times 10^{-5}$ 量级; 231 个指标对的宏平均排序 Spearman 为 0.99978。两组规则下的结论一致。

权重排序的秩相关较低 (0.53 与 0.66) 源于权重本身的分布形态: 22 个指标的权重密集在 0.0451–0.0455 的窄区间内, 任何微小扰动都会改变其相对次序, 而权重的实际数值变化极小 (L_1 变化约 10^{-3}), 对评分的影响可以忽略。相比之下, 阈值与指标对排序几乎不动, 且检出的记录中确有更大比例落在冲突上尾——book 域被剔除的 17 条里有 11.76% 超过主阈值, 而基线为 5%。基于这一结果, 本文保留全部记录并报告其影响, 而不作删除; 在无法确认成因的前提下, 删除记录会引入新的偏差。

二次面的表现亦予报告, 但不作事后改选。其嵌套 CV 宏平均标准化 RMSE 为 0.58901, 优于主模型的 0.63305, 检验集 R^2 也更高 (0.6817 对 0.6189)。但 153 个系数由 512 条配方估计, 且不区分结构零与舍入零 (511/512 行含零), 过拟合风险明确。按选模纪律, 主模型在选模阶段即已冻结, 不允许在看到检验集结果后更改, 故二次面仅作敏感性对照保留。域序对预处理场景的稳健性见图 5.18。




图 5.18 A1 七域排序在预设场景下的稳健性

5.6 本章小结

本问的三项交付如下。质量评分方面, 22 个指标经 A1 单点校准的方向统一后合成两个并列候选, 等权候选的 A1 宏平均为 0.49622 (95% 区间 $[0.49491, 0.49763]$), 稳定性加权 Huber 候选为 0.49848 ($[0.49657, 0.50043]$); A2/A3 与 A1 的同域差值四个区间全部跨零, 点估计均在千分位以下。冲突分析方面, 22 个指标构成 231 对, A1 各域的中位冲突度在

0.2712–0.4382 之间，最高的指标对为 `dsir_math` 与 `rps_doc_unigram_entropy` (0.5993)，消解采用稳定性加权 `Huber` 位置。配比建模方面，单纯形岭回归在 A4/A5 交叉验证上以 0.39860 略优于参考分量 OLS，同尺度检验集 A6/A7 的 $R^2 = 0.6189$ 、`Spearman` = 0.8327，136 个域对中 106 对有足够份额支持 10 个百分点替代。

本问的结论受三条限制约束。第一， Q 目前是受限候选分，793 份双人盲评尚未完成，故没有加权 `Kappa` 与设计加权 `Spearman`，两个候选并列而非择一；同时 7 个 `rps_*frac*` 字段的单位来源未核实，剔除后 A1 样本分的 P95 绝对差达 0.113048。第二，配比模型不具备跨尺度定量外推能力，60M 与 1B 上的 R^2 转负 (−7.93 与 −810.12)，`Spearman` 仍保持 0.73–0.83，可用的只是同尺度内的排序而非跨尺度预测。第三，配比域比损失目标多 4 个，这 4 个域的损失不可观测，是模型的结构性限制。

本问交付给问题二的是质量评分 Q 的可比尺度 ($[0, 1]$ ，A1 七域宏平均 0.496) 与 17 维配比 π 的单纯形定义，问题二须在此基础上构造含 N 、 D 、 Q 、 π 的广义标度律。

6 问题二的模型建立与求解

6.1 问题二分析

6.2 模型建立

6.3 模型求解

6.4 结果分析

6.5 模型验证与灵敏度分析

6.6 本章小结

7 问题三的模型建立与求解

7.1 问题三分析

7.2 模型建立

7.3 模型求解

7.4 结果分析

7.5 模型验证与灵敏度分析

7.6 本章小结

8 问题四的模型建立与求解

8.1 问题四分析

8.2 模型建立

8.3 模型求解

8.4 结果分析

8.5 模型验证与灵敏度分析

8.6 本章小结

9 模型稳健性与综合检验

9.1 参数灵敏度与随机性

9.2 消融实验

9.3 误差分解与失效案例

9.4 外推与分布偏移

10 模型的评价、改进与推广

10.1 模型的优点

10.2 模型的缺点

10.3 模型的改进方向

10.4 模型的推广

参考文献

- [1] Xia M, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, Proceedings of the 41st International Conference on Machine Learning (ICML), 2024.
- [2] Hoffmann J, Borgeaud S, Mensch A, et al., Training Compute-Optimal Large Language Models, Advances in Neural Information Processing Systems (NeurIPS): volume 35, 2022.
- [3] Bahri Y, Dyer E, Kaplan J, et al., Explaining Neural Scaling Laws, Proceedings of the National Academy of Sciences, 121(27), 2024.

附录 A 问题一主要程序

problem1.py

```
# 【粘贴问题一的核心代码。附录代码要点：  
# 1. 只放关键部分，不是把整个工程贴上来  
# 2. 必须有注释说明每一步在做什么  
# 3. 结果要能被正文的数字复现  
# 4. 函数名尽量与正文模型名对应，方便评委核对】
```

附录 B 问题二主要程序

problem2.py

附录 C 问题三主要程序

problem3.py

附录 D 问题四主要程序

problem4.py

附录 E 人工智能使用披露

按照第二十三届中国研究生数学建模竞赛 F 题《五、AI 使用规范》的要求，本文如实披露参赛过程中人工智能工具的使用情况。

E.1 使用的 AI 工具

工具名称	版本	提供方	使用时段
【例：Claude Code】	【例：Fable 5】	【例：Anthropic】	【例：09-23 至 09-26】
【工具二】	【版本号】	【提供方】	【时段】

表 E.1 参赛过程中使用的人工智能工具

E.2 使用环节与贡献范围

使用环节	AI 的具体贡献	参赛队的独立工作与核验
概念理解	【例：协助梳理【某方法】的基本原理与适用条件】	【例：查阅【文献】核实其推导；确认适用条件在本题数据上成立】
资料整理	【例：协助检索【某领域】的公开文献线索】	【例：逐篇核对原文与出处，正文引用均以正式发表文献为准】
代码调试	【例：协助排查【某函数】的报错与数值稳定性问题】	【例：自行完成算法设计与实现；对 AI 建议逐条测试，用【某验证】确认结果正确】
【其他环节】	【具体贡献】	【独立工作】

表 E.2 AI 工具的使用环节与贡献范围

E.3 对 AI 输出的核验与处理

针对人工智能工具给出的每项输出，参赛队均按以下流程处理：

1. 来源核验：凡涉及理论、公式与实验结论的内容，均回溯至正式发表的文献或可核验的公开数据，不以人工智能工具的输出作为学术依据；正文所有引用均指向正式文献（见参考文献）。

2. **独立复算**：凡涉及数值结果的内容，均由参赛队自行编写的程序（见附录 A–D）独立复算，论文报告的每个数值均可追溯至 `state/` 数字登记表.csv 登记的结果。
3. **处理说明**：【填写具体例子——例如“AI 曾建议采用某方法，经验证在本数据上不满足某前提，故改用另一方法”，或“AI 给出的某公式存在某错误，经推导修正为……”。真实的修正例子比空泛声明更有说服力。】

E.4 由参赛队独立完成的工作

本文的核心建模、数学推导、算法设计、参数选取、实验方案与结论论证，均由参赛队独立完成。具体包括：

- 问题的数学抽象与建模思路的提出；
- 全部数学模型的建立与公式推导；
- 求解算法的设计、实现与调参；
- 实验方案设计、结果计算与灵敏度分析；
- 数据预处理规则与评价指标的确定；
- 论文的撰写与图表制作。

人工智能工具在本参赛过程中的作用限于辅助性质的概念理解、资料检索与代码调试，未参与上述核心建模与推导工作。